Lý thuyết và Chu trình Hoạt động Toán học của LightGCN

Simplifying and Powering Graph Convolution Network for Recommendation

Tài liệu Tổng hợp từ Công trình Nghiên cứu gốc

Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, Meng Wang (SIGIR 2020)

Ngày 20 tháng 10 năm 2026

Tóm tắt nội dung

Tài liệu này trình bày chi tiết và hệ thống hóa toàn bộ chu trình hoạt động (workflow) cùng cơ sở toán học của mô hình **LightGCN** [He et al., SIGIR 2020]. LightGCN được thiết kế dựa trên phân tích thực nghiệm nghiêm ngặt (ablation study), chỉ ra rằng hai phép toán truyền thống trong GCN là *Biến đổi Đặc trưng (Feature Transformation W)* và *Hàm Kích hoạt Phi tuyến (σ)* không những không mang lại hiệu quả cho bài toán Lọc Cộng tác (Collaborative Filtering - CF) mà còn làm tăng độ phức tạp và gây khó khăn khi huấn luyện. LightGCN tối giản hóa kiến trúc, chỉ giữ lại hai thành phần cốt lõi: **Light Graph Convolution (LGC)** và **Layer Combination**. Báo cáo trình bày chi tiết khía cạnh toán học của thuật toán, phân tích tính tương đương với SGCN, APPNP, phân tích độ làm mịn bậc hai (2nd-order smoothness), thuật toán huấn luyện với BPR Loss, và một ví dụ tính toán số học cụ thể từng bước.

Mục lục

1 Đặt bài toán và Động lực Tối giản hóa GCN **2**
1.1 Hạn chế của các Mô hình GCN Truyền thống (như NGCF) 2

2 Chu trình Hoạt động Toán học của LightGCN **2**
2.1 1. Biểu diễn Đồ thị và Embedding Ban đầu (Layer 0) 2
2.2 2. Tích chập Đồ thị Tối giản (Light Graph Convolution - LGC) 3
2.2.1 Dạng Ma trận của LGC 3
2.3 3. Kết hợp Các Lớp (Layer Combination) 3
2.4 4. Dự đoán và Xếp hạng (Model Prediction) 3
2.5 5. Huấn luyện Mô hình và BPR Loss 4

3 Phân tích Lý thuyết và Tính Tương đương **4**
3.1 1. Tính Tương đương với Simplified GCN (SGCN) và Self-Connections 4
3.2 2. Mối liên hệ với APPNP và Khả năng Kiểm soát Over-smoothing 4
3.3 3. Phân tích Độ Làm mịn Bậc hai (2nd-Order Embedding Smoothness) 5

4 Ví dụ Tính toán Số học Từng bước (Step-by-Step Numerical Example) **5**
4.1 Bước 1: Tính toán LGC Lớp 1 5
4.2 Bước 2: Kết hợp Lớp ($K = 1, \alpha_0 = \alpha_1 = 0.5$) 6
4.3 Bước 3: Dự đoán Điểm Số Xếp hạng 6

1 Đặt bài toán và Động lực Tối giản hóa GCN

Trong các hệ thống Gợi ý (Recommender Systems) dựa trên Lọc Cộng tác (Collaborative Filtering - CF):

- Tập người dùng: $\mathcal{U} = \{u_1, u_2, \ldots, u_M\}$ với $|\mathcal{U}| = M$.
- Tập sản phẩm: $\mathcal{I} = \{i_1, i_2, \ldots, i_N\}$ với $|\mathcal{I}| = N$.
- Ma trận tương tác ẩn (implicit interaction matrix) $R \in \mathbb{R}^{M \times N}$:

$$R_{ui} = \begin{cases} 1, & \text{nếu người dùng } u \text{ đã tương tác với sản phẩm } i \\ 0, & \text{ngược lại} \end{cases} \tag{1}$$

1.1 Hạn chế của các Mô hình GCN Truyền thống (như NGCF)

Các mô hình GCN truyền thống như NGCF kế thừa quy tắc lan truyền từ GCN dành cho phân loại đồ thị:

$$e_u^{(k+1)} = \sigma\left(W_1 e_u^{(k)} + \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u||\mathcal{N}_i|}} \left(W_1 e_i^{(k)} + W_2(e_i^{(k)} \odot e_u^{(k)})\right)\right) \tag{2}$$

Phân tích Ablation Study của He et al. (2020): Trong bài toán phân loại nút, mỗi nút có thuộc tính đặc trưng giàu ngữ nghĩa (rich semantics như văn bản, chủ đề). Tuy nhiên, trong đồ thị tương tác người dùng - sản phẩm của CF, mỗi nút chỉ được biểu diễn bằng một ID (one-hot ID embedding) không có ngữ nghĩa nội tại ban đầu. Do đó:

1. Phép biến đổi ma trận trọng số W_1, W_2 không giúp học đặc trưng tốt hơn mà chỉ làm tăng chi phí tính toán và gây khó khăn cho việc tối ưu hội tụ.
2. Hàm phi tuyến $\sigma(\cdot)$ làm suy giảm khả năng tổng quát hóa và tăng nguy cơ triệt tiêu độ dốc (gradient vanishing).

Loại bỏ hoàn toàn W và σ giúp mô hình đạt loss huấn luyện thấp hơn rõ rệt và độ chính xác gợi ý (Recall@20, NDCG@20) tăng trung bình khoảng 16.0% so với NGCF.

2 Chu trình Hoạt động Toán học của LightGCN

2.1 1. Biểu diễn Đồ thị và Embedding Ban đầu (Layer 0)

Đồ thị hai phía người dùng - sản phẩm (User-Item Bipartite Graph) được biểu diễn qua ma trận kề $A \in \mathbb{R}^{(M+N)\times(M+N)}$:

$$A = \begin{pmatrix} \mathbf{0}^{M\times M} & R^{M\times N} \\ (R^T)^{N\times M} & \mathbf{0}^{N\times N} \end{pmatrix} \tag{3}$$

Tham số duy nhất có thể huấn luyện của LightGCN là ma trận Embedding ban đầu (Layer 0), trong đó mỗi vector embedding của nút là một vector cột kích thước $T \times 1$:

$$E^{(0)} = \begin{pmatrix} (e_{u_1}^{(0)})^T \\ \vdots \\ (e_{u_M}^{(0)})^T \\ (e_{i_1}^{(0)})^T \\ \vdots \\ (e_{i_N}^{(0)})^T \end{pmatrix} \in \mathbb{R}^{(M+N)\times T} \tag{4}$$

với T là số chiều của vector embedding (thông thường chọn $T = 64$).

2.2 2. Tích chập Đồ thị Tối giản (Light Graph Convolution - LGC)

Tại mỗi lớp lan truyền $k+1$, vector biểu diễn của người dùng u và sản phẩm i được cập nhật thuần túy qua phép lấy tổng có trọng số từ các xóm liền kề (neighborhood aggregation):

Quy tắc Lan truyền LGC (Local Node Level)

$$e_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u| \cdot |\mathcal{N}_i|}} e_i^{(k)} \tag{5}$$

$$e_i^{(k+1)} = \sum_{u \in \mathcal{N}_i} \frac{1}{\sqrt{|\mathcal{N}_i| \cdot |\mathcal{N}_u|}} e_u^{(k)} \tag{6}$$

Trong đó $\mathcal{N}_u$ và $\mathcal{N}_i$ lần lượt là tập láng giềng bậc 1 của người dùng u và sản phẩm i. Hệ số $\frac{1}{\sqrt{|\mathcal{N}_u||\mathcal{N}_i|}}$ là chuẩn hóa đối xứng (symmetric sqrt normalization), giữ cho độ lớn chuẩn của embedding ổn định qua các tầng lan truyền. LGC hoàn toàn không tích hợp self-connection tại mỗi bước lặp.

2.2.1 Dạng Ma trận của LGC

Đặt $D \in \mathbb{R}^{(M+N)\times(M+N)}$ là ma trận bậc đường chéo của A, với $D_{tt} = \sum_s A_{ts}$. Ma trận kề chuẩn hóa đối xứng được xác định:

$$\tilde{A} = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \tag{7}$$

Khi đó, phép lan truyền trên toàn bộ ma trận tại lớp $k+1$ được biểu diễn gọn gàng:

$$E^{(k+1)} = \tilde{A} E^{(k)} = \tilde{A}^{k+1} E^{(0)} \tag{8}$$

2.3 3. Kết hợp Các Lớp (Layer Combination)

Sau khi lan truyền qua K lớp, mô hình thu được $K+1$ biểu diễn embedding cho mỗi nút: $\{e_u^{(0)}, e_u^{(1)}, \ldots, e_u^{(K)}\}$. LightGCN tổng hợp các biểu diễn này thông qua tổ hợp tuyến tính:

$$e_u = \sum_{k=0}^{K} \alpha_k e_u^{(k)}, \quad e_i = \sum_{k=0}^{K} \alpha_k e_i^{(k)} \tag{9}$$

Dưới dạng ma trận:

Biểu diễn Cuối cùng qua Layer Combination

$$E = \sum_{k=0}^{K} \alpha_k E^{(k)} = \sum_{k=0}^{K} \alpha_k \tilde{A}^k E^{(0)} \tag{10}$$

Hệ số kết hợp tầng được cài đặt đồng đều $\alpha_k = \frac{1}{K+1}$. Thiết lập này mang lại hiệu suất tối ưu ổn định mà không cần điều chỉnh siêu tham số phức tạp. Số lớp thực nghiệm lý tưởng thường là $K = 3$ hoặc $K = 4$.

2.4 4. Dự đoán và Xếp hạng (Model Prediction)

Điểm số dự đoán mức độ ưa thích (ranking score) giữa người dùng u và sản phẩm i là tích vô hướng giữa hai biểu diễn cuối cùng:

$$\hat{y}_{ui} = e_u^T e_i \tag{11}$$

2.5 5. Huấn luyện Mô hình và BPR Loss

Mô hình được tối ưu bằng hàm mất mát **Bayesian Personalized Ranking (BPR) Loss**, khuyến khích điểm số của sản phẩm đã tương tác $i \in \mathcal{N}_u$ vượt trội so với sản phẩm chưa tương tác $j \notin \mathcal{N}_u$:

Hàm Mất mát BPR với Chuẩn hóa L2

$$\mathcal{L}_{\text{BPR}} = -\sum_{u=1}^{M} \sum_{i \in \mathcal{N}_u} \sum_{j \notin \mathcal{N}_u} \ln \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right) + \lambda \|E^{(0)}\|_F^2 \tag{12}$$

trong đó $\sigma(x) = \frac{1}{1+e^{-x}}$ là hàm sigmoid và λ là hệ số kiểm soát chuẩn hóa L_2 áp dụng riêng cho ma trận tham số ban đầu $E^{(0)}$.

3 Phân tích Lý thuyết và Tính Tương đương

3.1 1. Tính Tương đương với Simplified GCN (SGCN) và Self-Connections

SGCN bổ sung kết nối tự thân (self-connection) trực tiếp vào đồ thị thông qua $(A + I)$ và sử dụng biểu diễn tầng cuối cùng $E^{(K)}$. Bỏ qua việc tái co giãn độ lớn ma trận $(D + I)^{-\frac{1}{2}}$ để xét bản chất đại số, phép lan truyền của SGCN tương đương với:

$$(A + I)^K E^{(0)} = \sum_{k=0}^{K} \binom{K}{k} A^k E^{(0)} \tag{13}$$

Biểu thức trên chứng minh rằng: Phép lấy tổng có trọng số qua các tầng (Layer Combination) trong LightGCN đã **bao hàm toàn bộ hiệu ứng của self-connection**. Do đó, việc chèn thêm ma trận đơn vị I vào ma trận kề A trong LGC là hoàn toàn dư thừa.

3.2 2. Mối liên hệ với APPNP và Khả năng Kiểm soát Over-smoothing

APPNP lấy cảm hứng từ thuật toán Personalized PageRank, đưa embedding gốc $E^{(0)}$ quay trở lại ở mỗi bước lan truyền với xác suất dịch chuyển tức thời (teleport probability) $\beta \in (0, 1]$:

$$E^{(k+1)} = \beta E^{(0)} + (1 - \beta)\tilde{A}E^{(k)} \tag{14}$$

Sau K bước lặp, biểu diễn tầng cuối của APPNP có dạng khai triển:

$$E^{(K)} = \beta E^{(0)} + \beta(1 - \beta)\tilde{A}E^{(0)} + \beta(1 - \beta)^2\tilde{A}^2E^{(0)} + \cdots + (1 - \beta)^K\tilde{A}^K E^{(0)} \tag{15}$$

So sánh với công thức Layer Combination của LightGCN:

$$E = \sum_{k=0}^{K} \alpha_k \tilde{A}^k E^{(0)} \tag{16}$$

Bằng cách chọn hệ số α_k phù hợp, LightGCN hoàn toàn khôi phục lại cơ chế truyền tin của APPNP. Điều này giải thích vì sao LightGCN có thể lan truyền tầm xa qua nhiều tầng (K lớn) mà vẫn duy trì được tính đặc trưng cục bộ và đẩy lùi hiện tượng over-smoothing.

3.3 3. Phân tích Độ Làm mịn Bậc hai (2nd-Order Embedding Smoothness)

Xét LightGCN với $K = 2$, vector embedding tầng 2 của người dùng u được phân rã thành:

$$e_u^{(2)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u||\mathcal{N}_i|}} e_i^{(1)} = \sum_{v \in \mathcal{U}} c_{v \to u} e_v^{(0)} \tag{17}$$

trong đó trọng số tương tác bậc hai giữa người dùng v và người dùng u được tính tường minh:

$$c_{v \to u} = \frac{1}{\sqrt{|\mathcal{N}_u||\mathcal{N}_v|}} \sum_{i \in \mathcal{N}_u \cap \mathcal{N}_v} \frac{1}{|\mathcal{N}_i|} \tag{18}$$

Hệ số $c_{v \to u}$ phản ánh chính xác các nguyên lý nền tảng của Lọc cộng tác:

1. Số lượng sản phẩm đồng tương tác $|\mathcal{N}_u \cap \mathcal{N}_v|$ càng lớn thì mức ảnh hưởng càng cao.
2. Sản phẩm đồng tương tác càng ít phổ biến ($\frac{1}{|\mathcal{N}_i|}$ lớn) càng cung cấp tín hiệu cá nhân hóa mạnh mẽ hơn.
3. Người dùng v càng ít tương tác tổng thể ($\frac{1}{\sqrt{|\mathcal{N}_v|}}$ lớn) thì hành vi chung càng mang tính đặc trưng, đáng tin cậy hơn.

4 Ví dụ Tính toán Số học Từng bước (Step-by-Step Numerical Example)

Xét đồ thị gồm $M = 2$ người dùng (u_1, u_2) và $N = 2$ sản phẩm (i_1, i_2):

- u_1 liên kết với $\{i_1, i_2\} \implies |\mathcal{N}_{u_1}| = 2$.
- u_2 liên kết với $\{i_1\} \implies |\mathcal{N}_{u_2}| = 1$.
- i_1 liên kết với $\{u_1, u_2\} \implies |\mathcal{N}_{i_1}| = 2$.
- i_2 liên kết với $\{u_1\} \implies |\mathcal{N}_{i_2}| = 1$.

Khởi tạo embedding 2 chiều ($T = 2$):

$$e_{u_1}^{(0)} = \begin{pmatrix} 1.0 \\ 0.0 \end{pmatrix}, \quad e_{u_2}^{(0)} = \begin{pmatrix} 0.0 \\ 1.0 \end{pmatrix}, \quad e_{i_1}^{(0)} = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}, \quad e_{i_2}^{(0)} = \begin{pmatrix} 0.0 \\ 0.5 \end{pmatrix}$$

4.1 Bước 1: Tính toán LGC Lớp 1

Áp dụng công thức chuẩn hóa đối xứng:

$$e_{u_1}^{(1)} = \frac{1}{\sqrt{2 \cdot 2}} e_{i_1}^{(0)} + \frac{1}{\sqrt{2 \cdot 1}} e_{i_2}^{(0)} = \frac{1}{2} \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix} + \frac{1}{\sqrt{2}} \begin{pmatrix} 0.0 \\ 0.5 \end{pmatrix} \approx \begin{pmatrix} 0.250 \\ 0.604 \end{pmatrix}$$

$$e_{u_2}^{(1)} = \frac{1}{\sqrt{1 \cdot 2}} e_{i_1}^{(0)} = \frac{1}{\sqrt{2}} \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix} \approx \begin{pmatrix} 0.354 \\ 0.354 \end{pmatrix}$$

$$e_{i_1}^{(1)} = \frac{1}{\sqrt{2 \cdot 2}} e_{u_1}^{(0)} + \frac{1}{\sqrt{2 \cdot 1}} e_{u_2}^{(0)} = \frac{1}{2} \begin{pmatrix} 1.0 \\ 0.0 \end{pmatrix} + \frac{1}{\sqrt{2}} \begin{pmatrix} 0.0 \\ 1.0 \end{pmatrix} \approx \begin{pmatrix} 0.500 \\ 0.707 \end{pmatrix}$$

$$e_{i_2}^{(1)} = \frac{1}{\sqrt{1 \cdot 2}} e_{u_1}^{(0)} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1.0 \\ 0.0 \end{pmatrix} \approx \begin{pmatrix} 0.707 \\ 0.000 \end{pmatrix}$$

4.2 Bước 2: Kết hợp Lớp ($K = 1, \alpha_0 = \alpha_1 = 0.5$)

$$e_{u_1} = 0.5 \cdot e_{u_1}^{(0)} + 0.5 \cdot e_{u_1}^{(1)} = 0.5 \begin{pmatrix} 1.0 \\ 0.0 \end{pmatrix} + 0.5 \begin{pmatrix} 0.250 \\ 0.604 \end{pmatrix} = \begin{pmatrix} 0.625 \\ 0.302 \end{pmatrix}$$

$$e_{i_1} = 0.5 \cdot e_{i_1}^{(0)} + 0.5 \cdot e_{i_1}^{(1)} = 0.5 \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix} + 0.5 \begin{pmatrix} 0.500 \\ 0.707 \end{pmatrix} = \begin{pmatrix} 0.500 \\ 0.604 \end{pmatrix}$$

4.3 Bước 3: Dự đoán Điểm Số Xếp hạng

$$\hat{y}_{u_1,i_1} = e_{u_1}^T e_{i_1} = (0.625)(0.500) + (0.302)(0.604) = 0.3125 + 0.1824 = \mathbf{0.4949}$$

Tài liệu

[1] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, Meng Wang. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '20)*, 2020.

[2] Xiang Wang, Xiangnan He, Meng Wang, Fuli Feng, Tat-Seng Chua. Neural Graph Collaborative Filtering. In *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '19)*, 2019.

[3] Felix Wu, Amauri H. Souza Jr., Tianyi Zhang, Christopher Fifty, Tao Yu, Kilian Q. Weinberger. Simplifying Graph Convolutional Networks. In *Proceedings of the 36th International Conference on Machine Learning (ICML '19)*, 2019.

[4] Johannes Klicpera, Aleksandar Bojchevski, Stephan Günnemann. Predict then Propagate: Graph Neural Networks meet Personalized PageRank. In *International Conference on Learning Representations (ICLR)*, 2019.