Lý thuyết và Chu trình Hoạt động của Pareto HyperNetworks (PHN) trong Học Mặt cong Pareto (Pareto-Front Learning - PFL)

Báo cáo Phân tích Toán học Chi tiết dựa trên Nghiên cứu gốc Navon et al. (ICLR 2021)

Tài liệu Tổng hợp và Chuẩn hóa từ Công trình Nghiên cứu gốc
Aviv Navon, Aviv Shamsian, Gal Chechik, Ethan Fetaya (Bar-Ilan University & NVIDIA)

Ngày 19 tháng 10 năm 2026

Tóm tắt nội dung

Tài liệu này trình bày mô hình hóa toán học và chu trình hoạt động (workflow) toàn diện của kiến trúc **Pareto HyperNetworks (PHN)** giải quyết bài toán **Pareto-Front Learning (PFL)** dựa trên công trình *"Learning the Pareto Front with Hypernetworks"* [Navon et al., ICLR 2021]. Thay vì huấn luyện K mô hình rời rạc cho K hướng đánh đổi, PHN sử dụng một Hypernetwork duy nhất $h(r;\theta)$ nhận đầu vào là vector độ ưu tiên liên tục $r \in \mathcal{S}_m$ trên đơn hình (simplex) và sinh ra bộ tham số $\phi(\theta, r)$ cho mạng Target $f(\cdot;\phi)$. Báo cáo phân tích sâu cơ sở lý thuyết từ Định lý Hàm Ẩn (Implicit Function Theorem), điều kiện dừng Jacobian, sự khác biệt bản chất giữa hai biến thể **PHN-LS** và **PHN-EPO** trên mặt Pareto lõm, hiệu ứng thiên kiến quy nạp (inductive bias), các chỉ số đánh giá (Hypervolume & Uniformity), cùng ví dụ tính toán giải tích chi tiết.

Mục lục

1 Giới thiệu và Đặt bài toán Pareto-Front Learning (PFL) 3
1.1 Các Khái niệm Nền tảng về Tối ưu Pareto . . . 3
1.2 Định nghĩa Bài toán Pareto-Front Learning (PFL) . . . 3

2 Kiến trúc Pareto HyperNetworks (PHN) 3
2.1 Cấu trúc Toán học của Hypernetwork và Target Network . . . 4

3 Hai Phương pháp Huấn luyện và Cơ sở Lý thuyết của PHN 4
3.1 1. Biến thể PHN-LS (Linear Scalarization) . . . 4
3.1.1 Cơ sở Lý thuyết: Định lý Hàm Ẩn (Implicit Function Theorem) . . . 4
3.2 2. Biến thể PHN-EPO (Exact Pareto Optimization) . . . 5
3.2.1 Chu trình Tính toán Giả-Gradient trong PHN-EPO . . . 6

4 Thuật toán Tổng quát và Hiệu ứng Thiên kiến Quy nạp 7
4.1 Hiệu ứng Thiên kiến Quy nạp (Inductive Bias of Weight Sharing across Rays) . . 7

5 Hệ thống Thước đo Đánh giá (Evaluation Metrics) 7
5.1 1. Chỉ số Thể tích Siêu không gian (Hypervolume Indicator - HV) . . . 8
5.2 2. Chỉ số Độ Đồng đều / Căn chỉnh Tia (Uniformity Indicator) . . . 8

6 Ví dụ Giải tích và Minh họa Số học (Phụ lục B của Bài báo) 8
6.1 1. Phương trình Giải tích của Tập Pareto Set và Pareto Front 8
6.2 2. So sánh Ánh xạ Đầu ra của PHN-LS và PHN-EPO 9

7 Tài liệu Tham khảo 9

1 Giới thiệu và Đặt bài toán Pareto-Front Learning (PFL)

Xét bài toán tối ưu hóa đa mục tiêu (Multi-Objective Optimization - MOO) gồm m hàm mất mát không âm $\ell : \mathbb{R}^d \to \mathbb{R}^m_+$, viết dưới dạng vector:

$$\ell(\phi) = (\ell_1(\phi), \ell_2(\phi), \ldots, \ell_m(\phi))^T \in \mathbb{R}^m_+ \tag{1}$$

trong đó $\phi \in \mathbb{R}^d$ là bộ tham số của mô hình học máy đích (Target Network).

1.1 Các Khái niệm Nền tảng về Tối ưu Pareto

- **Quan hệ Thứ tự Bộ phận và Thống trị Pareto:** Ta ký hiệu $\ell(\phi_1) \leq \ell(\phi_2)$ nếu $\ell_i(\phi_1) \leq \ell_i(\phi_2)$ với mọi $i \in [m]$. Điểm $\phi_1 \in \mathbb{R}^d$ được gọi là thống trị (dominate) $\phi_2 \in \mathbb{R}^d$, ký hiệu $\ell(\phi_1) \prec \ell(\phi_2)$, khi và chỉ khi $\ell(\phi_1) \leq \ell(\phi_2)$ và tồn tại ít nhất một chỉ số $j \in [m]$ sao cho $\ell_j(\phi_1) < \ell_j(\phi_2)$.

- **Tối ưu Pareto Địa phương (Local Pareto Optimality):** Do hàm mất mát của mạng nơ-ron sâu thường không lồi (non-convex), ta xét tính tối ưu cục bộ. Một điểm ϕ^* là tối ưu Pareto địa phương nếu tồn tại một lân cận mở $\mathcal{N}(\phi^*)$ sao cho không có điểm $\phi \in \mathcal{N}(\phi^*)$ nào thỏa mãn $\ell(\phi) \prec \ell(\phi^*)$. Tập hợp ảnh của các nghiệm tối ưu Pareto trong không gian mục tiêu $\mathbb{R}^m_+$ được gọi là *Pareto Front*.

- **Đơn hình Độ ưu tiên (Preference Simplex):** Vector độ ưu tiên $r = (r_1, \ldots, r_m)^T$ biểu diễn tỷ lệ đánh đổi mong muốn giữa m mục tiêu, thuộc đơn hình chuẩn m chiều (có số chiều hình học là $m-1$):

$$\mathcal{S}_m = \left\{ r \in \mathbb{R}^m_+ \;\middle|\; \sum_{i=1}^{m} r_i = 1,\ r_i \geq 0 \right\} \tag{2}$$

1.2 Định nghĩa Bài toán Pareto-Front Learning (PFL)

Các phương pháp MOO dựa trên gradient trước đó như Pareto MTL [Lin et al., 2019] hay EPO [Mahapatra & Rajan, 2020] tuy định hướng được nghiệm về các vùng hoặc tia cụ thể trên mặt Pareto, nhưng gặp phải hai rào cản lớn khi triển khai thực tế:

1. **Tính mở rộng (Scalability):** Để bao phủ toàn bộ mặt Pareto m chiều, số lượng mô hình độc lập cần huấn luyện và lưu trữ tăng theo hàm mũ đối với số lượng mục tiêu m.

2. **Tính linh hoạt (Flexibility):** Hướng đánh đổi r phải được cố định trước khi huấn luyện. Nếu người vận hành muốn thay đổi r tại thời điểm chạy thực tế (runtime/deployment), hệ thống không thể đáp ứng nếu chưa huấn luyện lại mô hình cho tia mới đó.

Bài toán PFL đặt ra mục tiêu: Học một **mô hình điều kiện duy nhất** trong giai đoạn huấn luyện sao cho tại thời điểm suy luận (inference time), mô hình có thể nhận đầu vào là *bất kỳ* vector độ ưu tiên $r \in \mathcal{S}_m$ nào (kể cả những vector chưa từng xuất hiện lúc huấn luyện) và lập tức trả về bộ tham số tối ưu Pareto tương ứng với hướng đánh đổi đó.

2 Kiến trúc Pareto HyperNetworks (PHN)

PHN hiện thực hóa bài toán PFL bằng cách tham số hóa toàn bộ tập nghiệm Pareto thành một hàm liên tục thông qua kiến trúc Hypernetwork [Ha et al., 2017].

Sơ đồ Chu trình Truyền xuôi của Pareto HyperNetwork (PHN)

Preference $r \in \mathcal{S}_m$ (Lấy mẫu từ $\mathrm{Dir}(\alpha)$) $\longrightarrow$ Hypernetwork $h(r;\theta)$ $\xrightarrow{\phi(\theta,r)\in\mathbb{R}^d}$ Target Network $f\big(x;\phi(\theta,r)\big)$

Hypernetwork $h(r;\theta)$ $\downarrow$ Tham số học duy nhất $\theta \in \mathbb{R}^n$

Target Network $f\big(x;\phi(\theta,r)\big)$ $\downarrow$ Vector mất mát $\ell\big(x,y,\phi(\theta,r)\big) \in \mathbb{R}_+^m$

2.1 Cấu trúc Toán học của Hypernetwork và Target Network

1. **Mạng Đích (Target Network)** $f(x;\phi)$**:** Thực hiện tác vụ dự đoán trực tiếp trên dữ liệu đầu vào x với bộ trọng số $\phi \in \mathbb{R}^d$. Lưu ý: ϕ **không được cập nhật trực tiếp** bằng bộ tối ưu mà là đầu ra của Hypernetwork.

2. **Mạng Siêu sinh (Hypernetwork)** $h(r;\theta)$**:** Với bộ tham số huấn luyện $\theta \in \mathbb{R}^n$, mạng nhận vector $r \in \mathcal{S}_m$ và thực hiện ánh xạ:

$$h(\cdot;\theta) : \mathcal{S}_m \to \mathbb{R}^d, \quad r \mapsto \phi(\theta, r) = h(r;\theta)$$

Trong cài đặt chuẩn của bài báo, $h(r;\theta)$ gồm hai phần:

- *MLP Trích xuất Đặc trưng Chung:* Đưa $r \in \mathbb{R}^m$ qua 2 lớp ẩn kết nối đầy đủ (kích thước chiều ẩn $h_{\text{dim}} \in \{25, 100\}$) để tạo vector biểu diễn đặc trưng chung $e(r) \in \mathbb{R}^{h_{\text{dim}}}$.
- *Các Đầu Tuyến tính (Multiple Linear Heads):* Với mỗi tensor trọng số $\phi^{(l)}$ của lớp thứ l trong mạng Target, một lớp tuyến tính riêng biệt sẽ chiếu $e(r)$ thành đúng kích thước của $\phi^{(l)}$:

$$\phi^{(l)}(\theta, r) = \mathbf{W}_{\text{head}}^{(l)} e(r) + \mathbf{b}_{\text{head}}^{(l)}$$

3 Hai Phương pháp Huấn luyện và Cơ sở Lý thuyết của PHN

Tại mỗi vòng lặp huấn luyện, PHN lấy mẫu ngẫu nhiên một vector $r \sim \mathrm{Dirichlet}(\alpha)$ với $\alpha = (\alpha_0, \ldots, \alpha_0)^T$. Bài báo chọn $\alpha_0 = 0.2 < 1$: theo tính chất của phân bố Dirichlet, khi $\alpha_0 < 1$, mật độ xác suất tập trung cao tại các vùng biên và góc của đơn hình $\mathcal{S}_m$, giúp Hypernetwork học tốt các chế độ đánh đổi cực đoan (extreme trade-offs) vốn khó hội tụ hơn vùng trung tâm.

3.1 1. Biến thể PHN-LS (Linear Scalarization)

PHN-LS sử dụng trực tiếp vector đầu vào r làm trọng số vô hướng hóa tuyến tính cho các hàm mất mát. Hàm mục tiêu tổng thể cần tối ưu theo tham số θ là kỳ vọng trên cả phân bố Dirichlet của r và phân bố dữ liệu $\mathcal{D}$:

Hàm Mục tiêu của PHN-LS

$$\mathcal{L}_{\text{LS}}(\theta) = \mathbb{E}_{r\sim\mathrm{Dir}(\alpha),\,(x,y)\sim\mathcal{D}}\left[\sum_{i=1}^{m} r_i \ell_i\Big(x, y, \phi(\theta, r)\Big)\right], \quad \text{với } \phi(\theta, r) = h(r;\theta) \tag{3}$$

3.1.1 Cơ sở Lý thuyết: Định lý Hàm Ẩn (Implicit Function Theorem)

Để chứng minh rằng tồn tại một ánh xạ liên tục và trơn từ vector độ ưu tiên r sang bộ tham số tối ưu $\phi(r)$ (từ đó đảm bảo một mạng MLP như Hypernetwork có thể xấp xỉ được ánh xạ này), Navon et al. phát biểu Mệnh đề 1 dựa trên tập dữ liệu huấn luyện $\{(x_j, y_j)\}_{j=1}^N$:

Mệnh đề 1 (Navon et al., 2021 - Sự tồn tại của Ánh xạ Trọng số Trơn)

Giả sử $\phi(\hat{r})$ là một điểm dừng Pareto địa phương tương ứng với trọng số $\hat{r} \in \mathcal{S}_m$, tức là:

$$F(\hat{r}, \phi(\hat{r})) \triangleq \sum_{i=1}^{m} \sum_{j=1}^{N} \hat{r}_i \nabla_\phi \ell_i(x_j, y_j, \phi(\hat{r})) = \mathbf{0}$$

và giả sử ma trận Hessian của hàm vô hướng hóa $\mathbf{H}_\phi = \nabla^2_{\phi\phi} \left(\sum_{i=1}^{m} \sum_{j=1}^{N} \hat{r}_i \ell_i(x_j, y_j, \phi) \right)$ khả nghịch (full rank / non-singular) tại $\phi(\hat{r})$. Khi đó, theo Định lý Hàm Ẩn, tồn tại một lân cận mở U của $\hat{r}$ và một ánh xạ trơn duy nhất $\phi : U \to \mathbb{R}^d$ sao cho:

$$\forall r \in U : \quad \sum_{i=1}^{m} \sum_{j=1}^{N} r_i \nabla_\phi \ell_i\big(x_j, y_j, \phi(r)\big) = \mathbf{0} \tag{4}$$

Hệ quả và Cảnh báo về Điểm dừng:

- *Khả năng xấp xỉ:* Vì $\phi(r)$ là hàm trơn theo r, Định lý Xấp xỉ Phổ quát (Universal Approximation Theorem [Cybenko, 1989]) đảm bảo Hypernetwork $h(r; \theta)$ đủ rộng có thể xấp xỉ $\phi(r)$ với sai số nhỏ tùy ý.

- *Điều kiện điểm dừng của $\mathcal{L}_{LS}(\theta)$:* Áp dụng quy tắc đạo hàm hàm hợp (Chain Rule), gradient của hàm mục tiêu (3) theo θ là:

$$\nabla_\theta \mathcal{L}_{\text{LS}}(\theta) = \mathbb{E}_{r \sim \text{Dir}(\alpha)} \left[\left(\frac{\partial \phi(\theta, r)}{\partial \theta} \right)^T \sum_{i=1}^{m} r_i \nabla_\phi \ell_i\big(\phi(\theta, r)\big) \right] \tag{5}$$

  Nếu với mọi r, đầu ra $\phi(\theta, r)$ là điểm dừng Pareto ($\sum_i r_i \nabla_\phi \ell_i = \mathbf{0}$), thì hiển nhiên $\nabla_\theta \mathcal{L}_{\text{LS}}(\theta) = \mathbf{0}$. Tuy nhiên, chiều ngược lại không luôn đúng: có thể tồn tại các điểm dừng hoặc cực tiểu cục bộ của θ mà tại đó $\nabla_\theta \mathcal{L}_{\text{LS}}(\theta) = \mathbf{0}$ (do sự triệt tiêu khi lấy kỳ vọng qua r hoặc rơi vào không gian hạch của ma trận Jacobian $\frac{\partial \phi}{\partial \theta}$), nhưng $\sum_i r_i \nabla_\phi \ell_i \neq \mathbf{0}$. Dù vậy, thực nghiệm chứng minh SGD/Adam giúp PHN tránh được các cực tiểu giả này hiệu quả.

3.2 2. Biến thể PHN-EPO (Exact Pareto Optimization)

Hạn chế của PHN-LS: Giống như Linear Scalarization truyền thống, PHN-LS có hai nhược điểm lý thuyết: (1) Không thể tìm được nghiệm nằm trên phần lõm (concave part) của mặt Pareto [Boyd & Vandenberghe, 2004]; và (2) Trọng số tuyến tính r không tỷ lệ thuận trực tiếp với vị trí tia trong không gian mất mát.

Cơ chế Tia Nghịch đảo của PHN-EPO: Để khắc phục hoàn toàn hai nhược điểm trên, PHN-EPO kết hợp Hypernetwork với bộ giải EPO [Mahapatra & Rajan, 2020]. Với vector độ ưu tiên đầu vào $r \in \mathcal{S}_m$, PHN-EPO coi r là yêu cầu định hướng trong không gian loss và ép vector mất mát $\ell(\phi(\theta, r))$ phải hội tụ chính xác về **tia nghịch đảo** $r^{-1} = (1/r_1, \ldots, 1/r_m)^T$, được định nghĩa bởi hệ phương trình cân bằng tỷ lệ:

$$r_1 \ell_1\big(\phi(\theta, r)\big) = r_2 \ell_2\big(\phi(\theta, r)\big) = \cdots = r_m \ell_m\big(\phi(\theta, r)\big) \tag{6}$$

Ý nghĩa: Nếu mục tiêu i có độ ưu tiên r_i càng lớn, thì để tích $r_i \ell_i$ bằng các mục tiêu khác, giá trị mất mát ℓ_i buộc phải càng nhỏ.

3.2.1 Chu trình Tính toán Giả-Gradient trong PHN-EPO

Tại mỗi bước lặp với một mẫu r và mini-batch $\{(x_j, y_j)\}_{j=1}^{B}$:

1. Truyền xuôi qua Hypernetwork để lấy $\phi(\theta, r) = h(r; \theta)$ và tính vector mất mát hiện tại $\ell(\phi(\theta, r))$ cùng các ma trận gradient đối với tham số mạng đích chuẩn hóa $\nabla_\phi \ell_i(\phi(\theta, r))$.

2. Đưa vào bộ giải Quy hoạch Tuyến tính (LP) của EPO:

$$\beta = \mathrm{EPO}\big(\phi(\theta, r), \ell, r\big) \in \mathcal{S}_m$$

   Bộ giải EPO tìm tổ hợp lồi trọng số $\beta = (\beta_1, \ldots, \beta_m)^T$ ($\sum_{i=1}^{m} \beta_i = 1, \beta_i \geq 0$) trong bao lồi của các gradient $\mathrm{conv}(\{\nabla_\phi \ell_i\})$ sao cho: vừa tạo góc lớn nhất với vector kéo về tia cân bằng d_{bal} (để giảm độ lệch không đồng nhất μ_r), vừa đảm bảo không làm tăng các hàm mất mát khi đã ở gần tia r^{-1}.

3. Sử dụng β làm hệ số kết hợp để lan truyền ngược (backpropagate) qua Hypernetwork:

Công thức Cập nhật Hướng dốc của PHN-EPO

$$g_\theta^{\mathrm{EPO}} = \frac{1}{B} \sum_{j=1}^{B} \sum_{i=1}^{m} \beta_i \nabla_\theta \ell_i\Big(x_j, y_j, \phi(\theta, r)\Big) = \left(\frac{\partial h(r; \theta)}{\partial \theta}\right)^T \left[\frac{1}{B} \sum_{j=1}^{B} \sum_{i=1}^{m} \beta_i \nabla_\phi \ell_i\Big(x_j, y_j, \phi_r\Big)\right] \tag{7}$$

Lưu ý Toán học Quan trọng: Vì β thay đổi phụ thuộc vào trạng thái của ℓ và $\nabla_\phi \ell$ qua một bài toán LP tại mỗi bước, hướng cập nhật g_θ^{EPO} **không phải là đạo hàm của bất kỳ hàm mất mát cố định nào** (unlike PHN-LS). Do phải giải một bài toán LP (kích thước nhỏ theo m) ở mỗi bước, thời gian huấn luyện của PHN-EPO dài hơn PHN-LS (ví dụ: 27 phút so với 12 phút trên tập Multi-MNIST), nhưng bù lại đạt độ căn chỉnh tia (Uniformity) vượt trội.

4 Thuật toán Tổng quát và Hiệu ứng Thiên kiến Quy nạp

Algorithm 1: Thuật toán Huấn luyện Pareto HyperNetworks (PHN)

1. **Input:** Tham số Dirichlet $\alpha = (0.2, \ldots, 0.2)^T$, tốc độ học η, kích thước batch B.
2. Khởi tạo ngẫu nhiên bộ tham số Hypernetwork $\theta \in \mathbb{R}^n$.
3. **While** *chưa hội tụ* **do**:
   (a) Lấy mẫu vector độ ưu tiên: $r \sim \mathrm{Dir}(\alpha) \in \mathcal{S}_m$.
   (b) Sinh bộ trọng số mạng đích: $\phi(\theta, r) = h(\theta, r)$.
   (c) Lấy mẫu mini-batch dữ liệu: $\{(x_1, y_1), \ldots, (x_B, y_B)\}$.
   (d) **If** `Phương pháp == LS` **then**:

$$g_\theta \leftarrow \frac{1}{B} \sum_{i=1}^{m} \sum_{j=1}^{B} r_i \nabla_\theta \ell_i\big(x_j, y_j, \phi(\theta, r)\big)$$

   (e) **If** `Phương pháp == EPO` **then**:

$$\beta \leftarrow \mathrm{EPO}\big(\phi(\theta, r), \ell, r\big)$$

$$g_\theta \leftarrow \frac{1}{B} \sum_{i=1}^{m} \sum_{j=1}^{B} \beta_i \nabla_\theta \ell_i\big(x_j, y_j, \phi(\theta, r)\big)$$

   (f) Cập nhật tham số Hypernetwork: $\theta \leftarrow \theta - \eta g_\theta$.
4. **Return:** Bộ tham số Hypernetwork đã huấn luyện θ^*.
5. **Tại thời điểm Suy luận (Inference):** Với mọi vector $r_{\text{test}} \in \mathcal{S}_m$ bất kỳ do người dùng chọn, trích xuất tức thời mô hình Pareto tối ưu thông qua một lượt truyền xuôi $\phi^* = h(r_{\text{test}}; \theta^*)$.

4.1 Hiệu ứng Thiên kiến Quy nạp (Inductive Bias of Weight Sharing across Rays)

Một phát hiện thực nghiệm đáng chú ý trong bài báo (Mục 6 & Phụ lục C.2) là khi đánh giá PHN trên *cùng một tập các tia cố định* mà các mô hình đơn lẻ (như EPO, PMTL, LS) được huấn luyện chuyên biệt, PHN vẫn thường xuyên đạt chỉ số Hypervolume cao hơn. Nguyên nhân là do việc chia sẻ chung bộ tham số θ của Hypernetwork trên toàn bộ không gian đơn hình $\mathcal{S}_m$ tạo ra một **thiên kiến quy nạp (inductive bias)** đóng vai trò như một cơ chế điều chuẩn ngầm (implicit regularization), giúp truyền tải tri thức giữa các hướng đánh đổi lân cận và tránh bị kẹt vào các cực tiểu cục bộ kém chất lượng của từng tia riêng lẻ.

5 Hệ thống Thước đo Đánh giá (Evaluation Metrics)

Để lượng hóa đồng thời chất lượng hội tụ, độ phủ đa dạng và độ chính xác định hướng của mặt cong Pareto, hai chỉ số tiêu chuẩn được sử dụng:

5.1 1. Chỉ số Thể tích Siêu không gian (Hypervolume Indicator - HV)

Cho tập hợp các điểm mất mát thu được từ mô hình $S \subset \mathbb{R}_+^m$ và một điểm tham chiếu chặn trên (reference point) $\rho \in \mathbb{R}_+^m$ (yêu cầu mọi điểm $p \in S$ đều phải bị chặn bởi ρ, ví dụ $\rho = (2, 2)$ cho Multi-MNIST hoặc $\rho = (1, \ldots, 1)$ cho SARCOS). Chỉ số HV [Zitzler & Thiele, 1999] đo thể tích Euclid của vùng không gian bị thống trị bởi ít nhất một điểm trong S và giới hạn bởi ρ:

$$\mathrm{HV}(S) = \mathrm{VOL}\left(\left\{q \in \mathbb{R}_+^m \mid \exists p \in S : (p \leq q) \wedge (q \leq \rho)\right\}\right) = \mathrm{VOL}\left(\bigcup_{p \in S} \prod_{i=1}^{m} [p_i, \rho_i]\right) \tag{8}$$

trong đó $\prod_{i=1}^{m}[p_i, \rho_i]$ là hình hộp chữ nhật m chiều tạo bởi đỉnh p và điểm tham chiếu ρ. HV càng lớn chứng tỏ mặt Pareto tìm được càng tiến sát gốc tọa độ (hội tụ tốt) và trải càng rộng (đa dạng cao).

5.2 2. Chỉ số Độ Đồng đều / Căn chỉnh Tia (Uniformity Indicator)

Được đề xuất bởi Mahapatra & Rajan (2020) để đo mức độ khớp giữa nghiệm đầu ra $\ell(\phi_r)$ với tia nghịch đảo mục tiêu r^{-1}. Với một vector độ ưu tiên $r \in \mathcal{S}_m$, ta định nghĩa phân bố xác suất chuẩn hóa có trọng số $\hat{\ell} = (\hat{\ell}_1, \ldots, \hat{\ell}_m)^T$:

$$\hat{\ell}_j = \frac{r_j \ell_j(\phi_r)}{\sum_{i=1}^{m} r_i \ell_i(\phi_r)}, \quad \forall j \in \{1, \ldots, m\} \tag{9}$$

Nếu $\ell(\phi_r)$ nằm chính xác trên tia nghịch đảo r^{-1} theo phương trình (6), ta có $r_1\ell_1 = \cdots = r_m\ell_m$, dẫn tới $\hat{\ell}_j = \frac{1}{m}$ với mọi j (phân bố đều $\mathbf{u} = (\frac{1}{m}, \ldots, \frac{1}{m})^T$). Độ lệch không đồng nhất (non-uniformity) được đo bằng phân kỳ Kullback-Leibler (KL-divergence):

$$\mu_r\big(\ell(\phi_r)\big) = D_{\mathrm{KL}}\left(\hat{\ell} \,\middle\|\, \frac{1}{m}\mathbf{1}\right) = \sum_{j=1}^{m} \hat{\ell}_j \log\left(m\hat{\ell}_j\right) \tag{10}$$

Từ đó, chỉ số **Uniformity** được định nghĩa là:

$$\mathrm{Uniformity}(r) = 1 - \mu_r\big(\ell(\phi_r)\big) \tag{11}$$

Khi nghiệm nằm đúng trên tia r^{-1}, $D_{\mathrm{KL}} = 0$ và Uniformity đạt giá trị tối đa bằng 1.

6 Ví dụ Giải tích và Minh họa Số học (Phụ lục B của Bài báo)

Xét bài toán tối ưu 2 mục tiêu kinh điển ($m = 2$) trong không gian tham số $\phi \in \mathbb{R}^d$ ($d = 100$) có mặt cong Pareto lõm (non-convex/concave Pareto front):

$$\ell_1(\phi) = 1 - \exp\left(-\left\|\phi - \frac{1}{\sqrt{d}}\mathbf{1}\right\|_2^2\right), \quad \ell_2(\phi) = 1 - \exp\left(-\left\|\phi + \frac{1}{\sqrt{d}}\mathbf{1}\right\|_2^2\right) \tag{12}$$

6.1 1. Phương trình Giải tích của Tập Pareto Set và Pareto Front

Xét điều kiện tối ưu Pareto: Gradient của hai hàm mục tiêu lần lượt tỉ lệ với $\left(\phi - \frac{1}{\sqrt{d}}\mathbf{1}\right)$ và $\left(\phi + \frac{1}{\sqrt{d}}\mathbf{1}\right)$. Để hai vector gradient ngược hướng nhau (điều kiện cần của điểm dừng Pareto $\lambda_1\nabla\ell_1 + \lambda_2\nabla\ell_2 = \mathbf{0}$), nghiệm ϕ^* phải nằm trên đoạn thẳng nối hai tâm $\pm\frac{1}{\sqrt{d}}\mathbf{1}$:

$$\mathcal{PS} = \left\{\phi(\alpha) = \frac{\alpha}{\sqrt{d}}\mathbf{1} \,\middle|\, \alpha \in [-1, 1]\right\} \tag{13}$$

Vì $\|\frac{1}{\sqrt{d}}\mathbf{1}\|_2^2 = d \cdot \frac{1}{d} = 1$, ta tính được giá trị hai hàm mất mát theo tham số $\alpha \in [-1, 1]$:

$$\ell_1(\alpha) = 1 - e^{-(\alpha-1)^2}, \quad \ell_2(\alpha) = 1 - e^{-(\alpha+1)^2} \tag{14}$$

Đây là một đường cong lõm (concave) nối từ điểm $(0, 1 - e^{-4}) \approx (0, 0.982)$ (ứng với $\alpha = 1$) đến điểm $(1 - e^{-4}, 0) \approx (0.982, 0)$ (ứng với $\alpha = -1$).

6.2 2. So sánh Ánh xạ Đầu ra của PHN-LS và PHN-EPO

Giả sử người dùng truyền vào các vector độ ưu tiên $r = (r_1, r_2)^T \in \mathcal{S}_2$ tại thời điểm suy luận:

- **Tại hai điểm cực trị $r = (1, 0)^T$ và $r = (0, 1)^T$:**
  - Với $r = (1, 0)^T$ (chỉ ưu tiên ℓ_1): Hypernetwork sinh ra $\phi = +\frac{1}{\sqrt{d}}\mathbf{1}$ ($\alpha = 1$), cho kết quả $\ell_1 = 0$, $\ell_2 = 1 - e^{-4} \approx 0.982$. Chỉ số $\hat{\ell} = (0, 1)^T$ (giới hạn hội tụ đúng trục tọa độ).
  - Với $r = (0, 1)^T$ (chỉ ưu tiên ℓ_2): Hypernetwork sinh ra $\phi = -\frac{1}{\sqrt{d}}\mathbf{1}$ ($\alpha = -1$), cho kết quả $\ell_1 \approx 0.982$, $\ell_2 = 0$.
- **Tại hướng cân bằng trung tâm $r = (0.5, 0.5)^T$:**
  - *Nếu dùng Linear Scalarization thuần túy:* Vì mặt Pareto lõm, hàm tổng $0.5\ell_1(\alpha) + 0.5\ell_2(\alpha) = 1 - 0.5\left(e^{-(\alpha-1)^2} + e^{-(\alpha+1)^2}\right)$ đạt cực đại cục bộ tại $\alpha = 0$ (với giá trị $1 - e^{-1} \approx 0.632$) và chỉ đạt cực tiểu toàn cục tại hai biên $\alpha = \pm 1$ (với giá trị $0.5(1 - e^{-4}) \approx 0.491 < 0.632$). Do đó, LS bị hút văng ra hai đầu mút và hoàn toàn bỏ trống phần giữa của mặt Pareto.
  - *Với PHN-EPO:* Thuật toán ép nghiệm thỏa mãn phương trình tia nghịch đảo (6):

    $$0.5\ell_1(\alpha) = 0.5\ell_2(\alpha) \iff 1 - e^{-(\alpha-1)^2} = 1 - e^{-(\alpha+1)^2} \iff \alpha = 0$$

    Khi đó, $h\big((0.5, 0.5)^T; \theta^*\big) = \mathbf{0} \in \mathbb{R}^d$, thu được $\ell_1 = \ell_2 = 1 - e^{-1} \approx 0.632$. Kiểm tra độ đồng đều:

    $$\hat{\ell}_1 = \frac{0.5 \times 0.632}{0.5 \times 0.632 + 0.5 \times 0.632} = 0.5, \quad \hat{\ell}_2 = 0.5 \implies D_{\mathrm{KL}} = 0 \implies \text{Uniformity} = 1.0$$

- **Tại một hướng lệch bất kỳ, ví dụ $r = (0.8, 0.2)^T$ (chưa từng thấy lúc train):**
  - Tia nghịch đảo yêu cầu: $0.8\ell_1(\alpha) = 0.2\ell_2(\alpha) \iff 4\left(1 - e^{-(\alpha-1)^2}\right) = 1 - e^{-(\alpha+1)^2}$.
  - Giải phương trình phi tuyến trên miền $\alpha \in [-1, 1]$ cho nghiệm duy nhất $\alpha^* \approx 0.517$.
  - Ngay tại thời điểm inference, PHN-EPO nội suy trơn qua mạng MLP và xuất ra trọng số $\phi \approx \frac{0.517}{\sqrt{d}}\mathbf{1}$, tạo ra cặp mất mát $(\ell_1, \ell_2) \approx (0.208, 0.832)$, thỏa mãn chính xác tỷ lệ $\frac{\ell_2}{\ell_1} = \frac{0.832}{0.208} = 4 = \frac{r_1}{r_2}$ với Uniformity = 1.0.

7 Tài liệu Tham khảo

[1] Aviv Navon, Aviv Shamsian, Gal Chechik, Ethan Fetaya. "Learning the Pareto Front with Hypernetworks." *International Conference on Learning Representations (ICLR)*, 2021.

[2] Debabrota Mahapatra, Vaibhav Rajan. "Multi-task learning with user preferences: Gradient descent with controlled ascent in pareto optimization." *International Conference on Machine Learning (ICML)*, pp. 6597–6607, 2020.

[3] Xi Lin, Hui-Ling Zhen, Zhenhua Li, Qingfu Zhang, Sam Kwong. "Pareto Multi-Task Learning." *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, pp. 12060–12070, 2019.

[4] David Ha, Andrew M. Dai, Quoc V. Le. "HyperNetworks." *International Conference on Learning Representations (ICLR)*, 2017.

[5] George Cybenko. "Approximation by superpositions of a sigmoidal function." *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.

[6] Eckart Zitzler, Lothar Thiele. "Multiobjective evolutionary algorithms: a comparative case study and the strength pareto approach." *IEEE Transactions on Evolutionary Computation*, 3(4):257–271, 1999.