Lý thuyết và Chu trình Hoạt động Toàn diện của Pareto Multi-Task Learning (Pareto MTL)

Báo cáo Phân tích Toán học Chi tiết và Mã Nguồn LaTeX

Tài liệu Tổng hợp và Chuẩn hóa từ Công trình Nghiên cứu gốc

Xi Lin, Hui-Ling Zhen, Zhenhua Li, Qingfu Zhang, Sam Kwong (NeurIPS 2019)

Ngày 19 tháng 10 năm 2026

Tóm tắt nội dung

Tài liệu này trình bày chi tiết nền tảng lý thuyết, mô hình hóa toán học và chu trình hoạt động (workflow) từng bước của thuật toán **Pareto Multi-Task Learning (Pareto MTL)** [Lin et al., NeurIPS 2019]. Thuật toán giải quyết bài toán học đa nhiệm bằng cách phân rã không gian mục tiêu thành các bài toán con có ràng buộc dựa trên các vector độ ưu tiên đơn vị (unit preference vectors). Báo cáo cung cấp đầy đủ các điều kiện KKT, cấu trúc ma trận Gram của bài toán quy hoạch toàn phương đối mã (Dual QP), sự tương đương với phép vô hướng hóa tuyến tính thích ứng (adaptive linear scalarization), một ví dụ tính toán số học minh họa trực tiếp cơ chế kích hoạt biên β_j^*, cùng phân tích các giới hạn thực tế của thuật toán.

Mục lục

1 Tổng quan và Đặt bài toán **2**
1.1 Khái niệm Tối ưu Pareto . . . 2

2 Phân rã Bài toán MTL thành các Bài toán Con có Ràng buộc **2**
2.1 Định nghĩa Hình học của Vùng phụ Ω_k . . . 2
2.2 Mô hình hóa Bài toán Con thứ k . . . 2

3 Chu trình Hoạt động Toán học Từng bước (Step-by-Step Workflow) **3**
3.1 Giai đoạn 1: Tìm Nghiệm Khởi tạo Khả thi (Initialization Step) . . . 3
3.2 Giai đoạn 2: Tối ưu Bài toán Con có Ràng buộc (Main Optimization Step) . . . 4

4 Bản chất: Phép Vô hướng hóa Tuyến tính Thích ứng (Adaptive Linear Scalarization) **5**

5 Thuật toán Tổng quát (Algorithm Box) **6**

6 Ví dụ Tính toán Số học Chi tiết (Minh họa Cơ chế Kích hoạt Biên) **6**
6.1 Bước 1: Kiểm tra Ràng buộc và Tính Gradient tại $\theta_t = 1.0$ . . . 7
6.2 Bước 2: Giải Bài toán Đối mã Dual QP . . . 7

7 Các Giới hạn Thực nghiệm và Thách thức Mở rộng **8**

8 Tài liệu Tham khảo **9**

1 Tổng quan và Đặt bài toán

Trong Học Đa nhiệm (Multi-Task Learning - MTL), ta cần tối ưu đồng thời m nhiệm vụ trên một mô hình có tập tham số chia sẻ $\theta \in \mathbb{R}^n$. Vector hàm mất mát (loss vector) được định nghĩa là:

$$\mathcal{L}(\theta) = (\mathcal{L}_1(\theta), \mathcal{L}_2(\theta), \ldots, \mathcal{L}_m(\theta))^T \in \mathbb{R}_+^m \tag{1}$$

Do các nhiệm vụ thường xung đột (conflict) lẫn nhau, không tồn tại một nghiệm θ^* duy nhất tối thiểu hóa tất cả $\mathcal{L}_i(\theta)$ cùng lúc. Mục tiêu của bài toán là tìm tập hợp các nghiệm tối ưu Pareto (*Pareto optimal set*) đại diện cho các mức đánh đổi (trade-offs) khác nhau giữa các nhiệm vụ.

1.1 Khái niệm Tối ưu Pareto

- **Thống trị Pareto (Pareto Dominance):** Một nghiệm θ^a thống trị θ^b (ký hiệu $\theta^a \prec \theta^b$) nếu và chỉ nếu:

$$\mathcal{L}_i(\theta^a) \leq \mathcal{L}_i(\theta^b), \quad \forall i \in \{1, \ldots, m\} \quad \text{và} \quad \exists j \in \{1, \ldots, m\} : \mathcal{L}_j(\theta^a) < \mathcal{L}_j(\theta^b)$$

- **Nghiệm tối ưu Pareto (Pareto Optimality):** Nghiệm θ^* được gọi là tối ưu Pareto nếu không tồn tại $\hat{\theta}$ nào sao cho $\hat{\theta} \prec \theta^*$. Tập hợp tất cả các điểm θ^* tạo thành *Pareto Set*, và ảnh của nó trong không gian mục tiêu tạo thành *Pareto Front*.

- **Điểm tới hạn Pareto (Pareto Criticality):** Một điểm θ_t được gọi là tới hạn Pareto nếu trong lân cận cục bộ của nó không tồn tại hướng di chuyển $d \in \mathbb{R}^n$ nào giúp cải thiện đồng thời tất cả các hàm mục tiêu (tức không tồn tại d để $\nabla \mathcal{L}_i(\theta_t)^T d < 0$, $\forall i = 1, \ldots, m$).

2 Phân rã Bài toán MTL thành các Bài toán Con có Ràng buộc

Để thu được K nghiệm Pareto phân bố đều trên toàn bộ Pareto Front (bao gồm cả phần lồi và phần lõm mà Linear Scalarization truyền thống bỏ sót), Pareto MTL phân chia không gian mục tiêu $\mathbb{R}_+^m$ thành K vùng phụ hình nón Ω_k ($k = 1, \ldots, K$) thông qua tập các vector độ ưu tiên đơn vị (unit preference vectors) $\{u_1, u_2, \ldots, u_K\} \subset \mathbb{R}_+^m$ thỏa mãn $\|u_k\|_2 = 1$ và $u_{k,i} \geq 0$.

2.1 Định nghĩa Hình học của Vùng phụ Ω_k

Vùng phụ thứ k được định nghĩa là tập hợp các vector mục tiêu $v \in \mathbb{R}_+^m$ có tích vô hướng với u_k lớn nhất trong số tất cả K vector độ ưu tiên:

$$\Omega_k = \left\{ v \in \mathbb{R}_+^m \;\middle|\; u_j^T v \leq u_k^T v, \quad \forall j = 1, \ldots, K \right\} \tag{2}$$

Bản chất hình học: Vì $\|u_j\|_2 = \|u_k\|_2 = 1$, ta có $u_j^T v = \|v\|_2 \cos \angle(u_j, v)$. Trên góc phần tư thứ nhất $\mathbb{R}_+^m$, góc $\angle(u, v) \in [0, \pi/2]$ nên hàm cos nghịch biến. Do đó, điều kiện $u_k^T v \geq u_j^T v$ tương đương với $\angle(u_k, v) \leq \angle(u_j, v)$, tức là vector mất mát v tạo với vector độ ưu tiên u_k một góc nhọn nhỏ nhất (gần tia u_k nhất về mặt phương hướng).

2.2 Mô hình hóa Bài toán Con thứ k

Bài toán con thứ k tương ứng với vector độ ưu tiên u_k là bài toán tối ưu đa mục tiêu bị giới hạn trên miền Ω_k:

$$\begin{aligned} \min_{\theta} \quad & \mathcal{L}(\theta) = (\mathcal{L}_1(\theta), \mathcal{L}_2(\theta), \ldots, \mathcal{L}_m(\theta))^T \\ \text{s.t.} \quad & \mathcal{L}(\theta) \in \Omega_k \end{aligned} \tag{3}$$

Ràng buộc $\mathcal{L}(\theta) \in \Omega_k$ được viết lại thành $K-1$ hàm ràng buộc bất đẳng thức tuyến tính theo $\mathcal{L}(\theta)$ (do tại $j=k$, biểu thức hiển nhiên bằng 0):

$$\mathcal{G}_j(\theta) = (u_j - u_k)^T \mathcal{L}(\theta) = \sum_{i=1}^{m} (u_{j,i} - u_{k,i}) \mathcal{L}_i(\theta) \leq 0, \quad \forall j \in \{1, \ldots, K\} \setminus \{k\} \tag{4}$$

Bài toán Con Tối ưu Đa mục tiêu có Ràng buộc (Subproblem k)

$$\begin{aligned} \min_{\theta \in \mathbb{R}^n} \quad & \mathcal{L}(\theta) = (\mathcal{L}_1(\theta), \mathcal{L}_2(\theta), \ldots, \mathcal{L}_m(\theta))^T \\ \text{s.t.} \quad & \mathcal{G}_j(\theta) = (u_j - u_k)^T \mathcal{L}(\theta) \leq 0, \quad \forall j \in \{1, \ldots, K\} \setminus \{k\} \end{aligned} \tag{5}$$

3 Chu trình Hoạt động Toán học Từng bước (Step-by-Step Workflow)

Thuật toán Pareto MTL giải K bài toán con độc lập và song song thông qua quy trình 2 giai đoạn dựa trên độ dốc (gradient-based).

3.1 Giai đoạn 1: Tìm Nghiệm Khởi tạo Khả thi (Initialization Step)

Với tham số khởi tạo ngẫu nhiên θ_r, vector $\mathcal{L}(\theta_r)$ thường nằm ngoài vùng Ω_k. Thay vì dùng phép chiếu trực giao trong không gian $\mathbb{R}^n$ (tốn kém với mạng nơ-ron sâu), Pareto MTL sử dụng phương pháp hạ dốc tuần tự để ép nghiệm đi vào vùng Ω_k.

1. **Xác định tập chỉ số các ràng buộc bị vi phạm:**

$$I(\theta_r) = \{j \in \{1, \ldots, K\} \setminus \{k\} \mid \mathcal{G}_j(\theta_r) \geq 0\}$$

2. **Giải bài toán tìm hướng giảm cho các ràng buộc:** Bài toán nguyên (Primal):

$$\begin{aligned} (d_r, \alpha_r) = \arg \min_{d \in \mathbb{R}^n, \alpha \in \mathbb{R}} \quad & \alpha + \frac{1}{2}\|d\|_2^2 \\ \text{s.t.} \quad & \nabla \mathcal{G}_j(\theta_r)^T d \leq \alpha, \quad \forall j \in I(\theta_r) \end{aligned} \tag{6}$$

   Chuyển sang dạng đối mã KKT để giải trên không gian số chiều thấp $|I(\theta_r)|$:

$$\begin{aligned} \beta^* = \arg\min_{\beta} \quad & \frac{1}{2} \left\| \sum_{j \in I(\theta_r)} \beta_j \nabla \mathcal{G}_j(\theta_r) \right\|_2^2 \\ \text{s.t.} \quad & \sum_{j \in I(\theta_r)} \beta_j = 1, \quad \beta_j \geq 0, \ \forall j \in I(\theta_r) \end{aligned} \tag{7}$$

   Từ đó thu được hướng di chuyển $d_r = -\sum_{j \in I(\theta_r)} \beta_j^* \nabla \mathcal{G}_j(\theta_r)$.

3. **Cập nhật nghiệm tiền khởi tạo:**

$$\theta_r \leftarrow \theta_r + \eta_r d_r$$

   Lặp lại cho đến khi $I(\theta_r) = \emptyset$ (thu được θ_0 thỏa mãn $\mathcal{L}(\theta_0) \in \Omega_k$) hoặc chạm ngưỡng số vòng lặp khởi tạo tối đa.

3.2 Giai đoạn 2: Tối ưu Bài toán Con có Ràng buộc (Main Optimization Step)

Khi đã có nghiệm θ_t, thuật toán tiến hành giảm đồng thời các hàm mất mát $\mathcal{L}_i(\theta_t)$ trong khi vẫn giữ nghiệm không vượt ra khỏi ranh giới của Ω_k.

1. **Xác định tập ràng buộc kích hoạt ngưỡng ϵ (ϵ-active constraints):**

$$I_\epsilon(\theta_t) = \{j \in \{1, \dots, K\} \setminus \{k\} \mid \mathcal{G}_j(\theta_t) \geq -\epsilon\} \tag{8}$$

   với $\epsilon > 0$ là một ngưỡng dương nhỏ nhằm kích hoạt sớm lực đẩy trước khi nghiệm kịp vi phạm ranh giới của Ω_k.

2. **Bài toán Nguyên tìm Hướng Giảm Chung d_t (Primal Formulation):**

$$\begin{aligned} (d_t, \alpha_t) = \arg \min_{d \in \mathbb{R}^n,\, \alpha \in \mathbb{R}} \quad & \alpha + \frac{1}{2}\|d\|_2^2 \\ \text{s.t.} \quad & \nabla \mathcal{L}_i(\theta_t)^T d \leq \alpha, \quad \forall i = 1, \dots, m \\ & \nabla \mathcal{G}_j(\theta_t)^T d \leq \alpha, \quad \forall j \in I_\epsilon(\theta_t) \end{aligned} \tag{9}$$

   Theo Bổ đề 2 [Gebken et al., 2017], nghiệm (d_t, α_t) của bài toán (9) thỏa mãn:

   - Nếu θ_t là điểm tới hạn Pareto giới hạn trên Ω_k (*Restricted Pareto Critical*), thì $d_t = \mathbf{0} \in \mathbb{R}^n$ và $\alpha_t = 0$.
   - Nếu θ_t chưa phải là điểm tới hạn Pareto trên Ω_k, thì $\alpha_t \leq -\frac{1}{2}\|d_t\|_2^2 < 0$. Khi đó $\nabla \mathcal{L}_i(\theta_t)^T d_t \leq \alpha_t < 0$ $(\forall i)$ và $\nabla \mathcal{G}_j(\theta_t)^T d_t \leq \alpha_t < 0$ $(\forall j \in I_\epsilon)$, nghĩa là d_t là hướng giảm hợp lệ cho cả mục tiêu lẫn ràng buộc.

3. **Biến đổi sang Bài toán Đối mã KKT Quy mô Lớn (Scalable Dual Formulation):** Vì số lượng tham số mạng nơ-ron n rất lớn ($n \gg 10^6$), ta áp dụng điều kiện KKT cho bài toán lồi (9). Hàm Lagrange tương ứng là:

$$L(d, \alpha, \lambda, \beta) = \alpha + \frac{1}{2}\|d\|_2^2 + \sum_{i=1}^{m} \lambda_i \left(\nabla \mathcal{L}_i(\theta_t)^T d - \alpha\right) + \sum_{j \in I_\epsilon(\theta_t)} \beta_j \left(\nabla \mathcal{G}_j(\theta_t)^T d - \alpha\right)$$

   Lấy đạo hàm theo d và α bằng 0:

$$\frac{\partial L}{\partial d} = 0 \implies d_t = -\left(\sum_{i=1}^{m} \lambda_i \nabla \mathcal{L}_i(\theta_t) + \sum_{j \in I_\epsilon(\theta_t)} \beta_j \nabla \mathcal{G}_j(\theta_t)\right) \tag{10}$$

$$\frac{\partial L}{\partial \alpha} = 0 \implies \sum_{i=1}^{m} \lambda_i + \sum_{j \in I_\epsilon(\theta_t)} \beta_j = 1 \tag{11}$$

   Thay vào hàm Lagrange, ta thu được Bài toán Quy hoạch Toàn phương Đối mã (Dual QP):

Bài toán Tối ưu Đối mã KKT (Dual QP Subproblem)

$$
\begin{aligned}
(\lambda^*, \beta^*) = \arg\max_{\lambda,\beta} \quad & -\frac{1}{2}\left\| \sum_{i=1}^{m} \lambda_i \nabla \mathcal{L}_i(\theta_t) + \sum_{j \in I_\epsilon(\theta_t)} \beta_j \nabla \mathcal{G}_j(\theta_t) \right\|_2^2 \\
\text{s.t.} \quad & \sum_{i=1}^{m} \lambda_i + \sum_{j \in I_\epsilon(\theta_t)} \beta_j = 1 \\
& \lambda_i \geq 0, \quad \forall i \in \{1, \ldots, m\} \\
& \beta_j \geq 0, \quad \forall j \in I_\epsilon(\theta_t)
\end{aligned}
\tag{12}
$$

4. **Biểu diễn Ma trận Gram để Lập trình Thực thi:** Đặt $p = |I_\epsilon(\theta_t)|$ và gom các nhân tử Lagrange thành một vector cột duy nhất $\gamma = [\lambda_1, \ldots, \lambda_m, \beta_{j_1}, \ldots, \beta_{j_p}]^T \in \mathbb{R}^{m+p}$. Đặt ma trận chứa các vector gradient cột là:

$$
\mathbf{J} = \begin{bmatrix} \nabla \mathcal{L}_1(\theta_t) & \ldots & \nabla \mathcal{L}_m(\theta_t) & \nabla \mathcal{G}_{j_1}(\theta_t) & \ldots & \nabla \mathcal{G}_{j_p}(\theta_t) \end{bmatrix} \in \mathbb{R}^{n \times (m+p)}
$$

Bài toán (12) trở thành dạng chuẩn tắc của các bộ giải QP (như `cvxopt`):

$$
\min_{\gamma \in \mathbb{R}^{m+p}} \frac{1}{2} \gamma^T \mathbf{M} \gamma \quad \text{s.t.} \quad \mathbf{1}^T \gamma = 1, \ \gamma \geq \mathbf{0} \tag{13}
$$

trong đó $\mathbf{M} = \mathbf{J}^T \mathbf{J} \in \mathbb{R}^{(m+p)\times(m+p)}$ là ma trận Gram đối xứng nửa xác định dương chứa các tích vô hướng giữa các gradient. Kích thước bài toán giảm từ $n > 10^6$ xuống còn $m+p$ (thường < 10).

5. **Cập nhật Tham số Mô hình:** Sau khi giải ra (λ^*, β^*), tính hướng giảm d_t theo (10) và cập nhật tham số:

$$
\theta_{t+1} = \theta_t + \eta d_t = \theta_t - \eta \left(\sum_{i=1}^{m} \lambda_i^* \nabla \mathcal{L}_i(\theta_t) + \sum_{j \in I_\epsilon(\theta_t)} \beta_j^* \nabla \mathcal{G}_j(\theta_t) \right) \tag{14}
$$

4 Bản chất: Phép Vô hướng hóa Tuyến tính Thích ứng (Adaptive Linear Scalarization)

Mặc dù xuất phát từ tối ưu đa mục tiêu có ràng buộc, Pareto MTL có thể được biến đổi tương đương về một hàm mất mát đại diện (surrogate loss) dạng tổng có trọng số biến thiên theo từng bước lặp.

Do $\nabla \mathcal{G}_j(\theta_t) = \sum_{i=1}^{m} (u_{j,i} - u_{k,i}) \nabla \mathcal{L}_i(\theta_t)$, thay vào công thức của d_t:

$$
\begin{aligned}
d_t &= -\left(\sum_{i=1}^{m} \lambda_i^* \nabla \mathcal{L}_i(\theta_t) + \sum_{j \in I_\epsilon(\theta_t)} \beta_j^* \sum_{i=1}^{m} (u_{j,i} - u_{k,i}) \nabla \mathcal{L}_i(\theta_t) \right) \\
&= -\sum_{i=1}^{m} \left[\lambda_i^* + \sum_{j \in I_\epsilon(\theta_t)} \beta_j^* (u_{j,i} - u_{k,i}) \right] \nabla \mathcal{L}_i(\theta_t) = -\sum_{i=1}^{m} \alpha_i \nabla \mathcal{L}_i(\theta_t)
\end{aligned}
$$

Điều này tương đương với việc thực hiện hạ dốc (Gradient Descent) trên hàm mục tiêu vô hướng hóa:

$$
\mathcal{L}_{\text{surrogate}}(\theta_t) = \sum_{i=1}^{m} \alpha_i \mathcal{L}_i(\theta_t) \tag{15}
$$

với trọng số động α_i tại bước t được cấu thành từ hai phần:

$$\alpha_i = \underbrace{\lambda_i^*}_{\substack{\text{Thành phần cân bằng độ dốc} \\ \text{(tương tự MGDA)}}} + \underbrace{\sum_{j \in I_\epsilon(\theta_t)} \beta_j^*(u_{j,i} - u_{k,i})}_{\substack{\text{Thành phần lực kéo định hướng} \\ \text{ép nghiệm quay về vùng } \Omega_k}} \tag{16}$$

- Khi nghiệm nằm sâu bên trong vùng Ω_k ($I_\epsilon(\theta_t) = \emptyset$), số hạng thứ hai triệt tiêu ($\alpha_i = \lambda_i^*$), Pareto MTL hoạt động giống hệt MGDA để hội tụ nhanh về mặt Pareto.
- Khi nghiệm chạm hoặc vượt biên ($I_\epsilon(\theta_t) \neq \emptyset$), $\beta_j^* > 0$ xuất hiện, làm thay đổi trọng số α_i (thậm chí một số α_i có thể nhận giá trị âm tạm thời như minh họa ở Hình 10 trong bài báo gốc) để bẻ hướng quỹ đạo nghiệm quay trở lại vùng ưu tiên Ω_k.

5 Thuật toán Tổng quát (Algorithm Box)

Algorithm 1: Thuật toán Pareto MTL

1. **Input:** Tập K vector độ ưu tiên đơn vị $\{u_1, u_2, \ldots, u_K\}$, tốc độ học η_r, η, ngưỡng biên $\epsilon > 0$.
2. **For** $k = 1$ **to** K **do** *(có thể chạy song song hoàn toàn)*:
   - Khởi tạo ngẫu nhiên bộ tham số $\theta_r^{(k)}$.
   - **Giai đoạn 1 (Initialization):** Cập nhật tuần tự $\theta_r^{(k)}$ theo hướng giảm các ràng buộc vi phạm $\mathcal{G}_j(\theta_r^{(k)}) \geq 0$ (Công thức 6) để thu được điểm khởi tạo $\theta_0^{(k)}$.
   - **Giai đoạn 2 (Main Loop): For** $t = 0$ **to** $T - 1$ **do**:
     (a) Xác định tập ràng buộc kích hoạt $I_\epsilon(\theta_t^{(k)}) = \{j \neq k \mid (u_j - u_k)^T \mathcal{L}(\theta_t^{(k)}) \geq -\epsilon\}$.
     (b) Tính các gradient $\nabla\mathcal{L}_i(\theta_t^{(k)})$ $(\forall i)$ và $\nabla\mathcal{G}_j(\theta_t^{(k)}) = \sum_{i=1}^m (u_{j,i} - u_{k,i}) \nabla\mathcal{L}_i(\theta_t^{(k)})$ $(\forall j \in I_\epsilon)$.
     (c) Lập ma trận Gram $\mathbf{M}$ và giải bài toán Dual QP (12) để tìm $(\lambda^{(k)}, \beta^{(k)})$.
     (d) Tính trọng số thích ứng: $\alpha_i^{(k)} = \lambda_i^{(k)} + \sum_{j \in I_\epsilon} \beta_j^{(k)}(u_{j,i} - u_{k,i})$.
     (e) Tính hướng cập nhật: $d_t^{(k)} = -\sum_{i=1}^m \alpha_i^{(k)} \nabla\mathcal{L}_i(\theta_t^{(k)})$.
     (f) Cập nhật tham số: $\theta_{t+1}^{(k)} = \theta_t^{(k)} + \eta d_t^{(k)}$.
3. **Output:** Tập hợp K nghiệm tối ưu Pareto đại diện $\{\theta_T^{(1)}, \theta_T^{(2)}, \ldots, \theta_T^{(K)}\}$.

6 Ví dụ Tính toán Số học Chi tiết (Minh họa Cơ chế Kích hoạt Biên)

Để thấy rõ sự khác biệt giữa Pareto MTL và MGDA, ta xét bài toán khi ràng buộc vùng bị kích hoạt ($I_\epsilon \neq \emptyset$). Xét bài toán 2 nhiệm vụ ($m = 2$) với tham số một chiều $\theta \in \mathbb{R}$:

$$\mathcal{L}_1(\theta) = \theta^2, \quad \mathcal{L}_2(\theta) = (\theta - 2)^2$$

Tập Pareto Set thực sự của bài toán này là đoạn $\theta \in [0, 2]$. Giả sử ta chia không gian thành $K = 2$ vùng bởi hai vector đơn vị:

$$u_1 = (0.8, 0.6)^T, \quad u_2 = (0.6, 0.8)^T \quad \text{(thỏa mãn } \|u_1\|_2 = \|u_2\|_2 = 1)$$

Ta giải bài toán con $k = 1$ (ưu tiên vùng Ω_1 gần trục $\mathcal{L}_2$, tức yêu cầu $\mathcal{L}_1$ phải nhỏ hơn so với $\mathcal{L}_2$). Đặt ngưỡng $\epsilon = 0.05$.

6.1 Bước 1: Kiểm tra Ràng buộc và Tính Gradient tại $\theta_t = 1.0$

Giả sử tại vòng lặp t, nghiệm hiện tại đang ở vị trí trung tâm $\theta_t = 1.0$:

- Giá trị hàm mất mát: $\mathcal{L}_1(1.0) = 1.0, \quad \mathcal{L}_2(1.0) = (1.0 - 2)^2 = 1.0.$
- Đạo hàm: $g_1 = \nabla\mathcal{L}_1(1.0) = 2\theta_t = 2.0, \quad g_2 = \nabla\mathcal{L}_2(1.0) = 2(\theta_t - 2) = -2.0.$

Vector hiệu độ ưu tiên:

$$u_2 - u_1 = \begin{pmatrix} 0.6 - 0.8 \\ 0.8 - 0.6 \end{pmatrix} = \begin{pmatrix} -0.2 \\ 0.2 \end{pmatrix}$$

Kiểm tra hàm ràng buộc $\mathcal{G}_2(\theta_t)$:

$$\mathcal{G}_2(1.0) = (u_2 - u_1)^T \mathcal{L}(1.0) = -0.2(1.0) + 0.2(1.0) = 0.0$$

Vì $\mathcal{G}_2(1.0) = 0.0 \geq -\epsilon = -0.05$, nghiệm đang nằm ngay trên biên phân chia hai vùng! Ràng buộc $j = 2$ bị kích hoạt: $I_\epsilon(1.0) = \{2\}$.

Tính gradient của hàm ràng buộc $\mathcal{G}_2$:

$$\nabla\mathcal{G}_2(1.0) = -0.2\nabla\mathcal{L}_1(1.0) + 0.2\nabla\mathcal{L}_2(1.0) = -0.2(2.0) + 0.2(-2.0) = -0.8$$

6.2 Bước 2: Giải Bài toán Đối mã Dual QP

Lưu ý rằng nếu dùng thuật toán MGDA thông thường (không có ràng buộc $\mathcal{G}_2$), vì $g_1 = 2.0$ và $g_2 = -2.0$ ngược hướng và bằng nhau về độ lớn, MGDA sẽ cho $\lambda_1 = 0.5, \lambda_2 = 0.5 \implies d_t = 0$ và dừng ngay tại $\theta_t = 1.0$, bất chấp việc người dùng muốn tìm nghiệm lệch về vùng Ω_1.

Với Pareto MTL, bài toán đối mã (12) có 3 biến $(\lambda_1, \lambda_2, \beta_2) \geq 0$ thỏa mãn $\lambda_1 + \lambda_2 + \beta_2 = 1$:

$$\min_{\lambda_1,\lambda_2,\beta_2 \geq 0} \frac{1}{2} (2.0\lambda_1 - 2.0\lambda_2 - 0.8\beta_2)^2 \quad \text{s.t.} \quad \lambda_1 + \lambda_2 + \beta_2 = 1$$

Tuy nhiên, hãy xét kỹ: nếu biểu thức trong bình phương bằng 0, thì $d_t = 0$. Điểm $\theta_t = 1.0$ nằm trên Pareto Front toàn cục nên không thể giảm đồng thời cả $\mathcal{L}_1, \mathcal{L}_2$ và $\mathcal{G}_2$. Để thấy quá trình di chuyển từ vùng vi phạm về vùng khả thi (Giai đoạn 1 hoặc khi chưa chạm mặt Pareto trong không gian nhiều chiều), tại $\theta_t = 1.0$, nếu chạy Bước Khởi tạo (chỉ xét $I(\theta_t) = \{2\}$):

$$\beta_2^* = 1 \implies d_r = -\beta_2^* \nabla\mathcal{G}_2(1.0) = -1(-0.8) = +0.8 \quad (\text{nếu } u_1 = (0.6, 0.8)^T)$$

Với $u_1 = (0.8, 0.6)^T$ (yêu cầu $\mathcal{L}_1 > \mathcal{L}_2$ vì $u_1^T\mathcal{L} \geq u_2^T\mathcal{L} \iff 0.8\mathcal{L}_1 + 0.6\mathcal{L}_2 \geq 0.6\mathcal{L}_1 + 0.8\mathcal{L}_2 \iff 0.2\mathcal{L}_1 - 0.2\mathcal{L}_2 \geq 0 \iff \mathcal{L}_1 \geq \mathcal{L}_2$):

- Hướng giảm của $\mathcal{G}_2$ là $-\nabla\mathcal{G}_2(1.0) = -(-0.8) = +0.8 > 0$.
- Khi cập nhật $\theta_{t+1} = 1.0 + \eta(0.8) > 1.0$, θ tăng lên (ví dụ $\theta = 1.2$), làm $\mathcal{L}_1(1.2) = 1.44 > \mathcal{L}_2(1.2) = 0.64$, đưa nghiệm đi sâu vào đúng vùng Ω_1 ($\mathcal{L}_1 \geq \mathcal{L}_2$).

Xét thêm một trường hợp trong không gian 2 chiều $\theta = (\theta_1, \theta_2)^T \in \mathbb{R}^2$ để thấy rõ cả λ^* và β^* cùng dương tại Giai đoạn 2: Giả sử tại bước t, ta có các vector gradient tại biên ($I_\epsilon = \{2\}$):

$$\nabla\mathcal{L}_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \nabla\mathcal{L}_2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix}, \quad \nabla\mathcal{G}_2 = -0.2\nabla\mathcal{L}_1 + 0.2\nabla\mathcal{L}_2 = \begin{pmatrix} 0 \\ -0.8 \end{pmatrix}$$

Biểu thức tổ hợp lồi của gradient:

$$v(\lambda_1, \lambda_2, \beta_2) = \lambda_1 \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \lambda_2 \begin{pmatrix} 1 \\ -2 \end{pmatrix} + \beta_2 \begin{pmatrix} 0 \\ -0.8 \end{pmatrix} = \begin{pmatrix} \lambda_1 + \lambda_2 \\ 2\lambda_1 - 2\lambda_2 - 0.8\beta_2 \end{pmatrix}$$

Từ $\lambda_1 + \lambda_2 = 1 - \beta_2$, hàm mục tiêu Dual QP cần cực tiểu hóa là:

$$f(\lambda_1, \lambda_2, \beta_2) = \frac{1}{2}\left[(1-\beta_2)^2 + (2\lambda_1 - 2\lambda_2 - 0.8\beta_2)^2\right]$$

Để thành phần thứ hai bằng 0, ta chọn $2\lambda_1 - 2\lambda_2 - 0.8\beta_2 = 0 \iff \lambda_1 - \lambda_2 = 0.4\beta_2$. Kết hợp với $\lambda_1 + \lambda_2 = 1 - \beta_2 \geq 0$ và điều kiện $\lambda_2 \geq 0 \implies 1 - \beta_2 - 0.4\beta_2 \geq 0 \implies \beta_2 \leq \frac{1}{1.4} = \frac{5}{7} \approx 0.714$. Hàm còn lại là $\frac{1}{2}(1-\beta_2)^2$ đạt cực tiểu trên miền $\beta_2 \in [0, 5/7]$ tại biên $\beta_2^* = \frac{5}{7}$. Suy ra nghiệm tối ưu của Dual QP:

$$\beta_2^* = \frac{5}{7} \approx 0.714, \quad \lambda_1^* = \frac{2}{7} \approx 0.286, \quad \lambda_2^* = 0$$

Khi đó, trọng số vô hướng hóa thích ứng α_i (Công thức 18) là:

$$\alpha_1 = \lambda_1^* + \beta_2^*(u_{2,1} - u_{1,1}) = \frac{2}{7} + \frac{5}{7}(-0.2) = \frac{1}{7} \approx 0.143$$

$$\alpha_2 = \lambda_2^* + \beta_2^*(u_{2,2} - u_{1,2}) = 0 + \frac{5}{7}(0.2) = \frac{1}{7} \approx 0.143$$

Hướng cập nhật tổng hợp:

$$d_t = -\left(\frac{1}{7}\nabla\mathcal{L}_1 + \frac{1}{7}\nabla\mathcal{L}_2\right) = -\begin{pmatrix} 2/7 \\ 0 \end{pmatrix} \neq \mathbf{0}$$

Nhờ có $\beta_2^* = 5/7 > 0$, hướng cập nhật d_t vừa làm giảm cả hai hàm mục tiêu ($\nabla\mathcal{L}_1^T d_t = \nabla\mathcal{L}_2^T d_t = -2/7 < 0$), vừa giữ cho nghiệm trượt dọc theo biên mà không vi phạm vùng Ω_1 ($\nabla\mathcal{G}_2^T d_t = 0$).

7 Các Giới hạn Thực nghiệm và Thách thức Mở rộng

Dựa trên phần Phụ lục (Supplementary Material) của công trình nghiên cứu gốc, khi áp dụng Pareto MTL vào các hệ thống thực tế cần lưu ý 4 giới hạn cốt lõi sau:

1. **Lời nguyền Số chiều khi Số lượng Nhiệm vụ lớn (Many-Task Learning):** Dưới các giả thiết trơn thông thường, Pareto Front của bài toán m mục tiêu là một đa tạp (manifold) có số chiều $m-1$. Nếu cần p điểm phân bố đều trên mỗi chiều để đại diện tốt cho mặt Pareto, tổng số vector độ ưu tiên cần thiết sẽ tăng theo hàm mũ: $K = p^{m-1}$ (ví dụ: $p = 5$ cần 25 mô hình cho 3 tasks, 125 mô hình cho 4 tasks). Đồng thời, kích thước bài toán Dual QP tại mỗi bước lặp là $m + |I_\epsilon| \leq m + p^{m-1} - 1$ cũng tăng theo cấp số nhân, gây quá tải chi phí tính toán.

2. **Sự Mất cân bằng về Độ khó và Độ lớn Gradient giữa các Nhiệm vụ:** Pareto MTL ngầm định rằng các nhiệm vụ có thang đo (scale) và độ khó tương đương nhau khi chia đều các vector đơn vị u_k. Nếu một nhiệm vụ có biên độ gradient lớn gấp nhiều lần nhiệm vụ khác, hình học của các phân vùng Ω_k bị bóp méo nghiêm trọng. Khác với MGDA (vốn bị hút về nhiệm vụ có gradient nhỏ/khó hơn hoặc ngược lại tùy cấu trúc), các nghiệm của Pareto MTL khi mất cân bằng nặng sẽ bị dồn cục về một phía thay vì trải đều.

3. **Khoảng cách giữa Tối ưu hóa và Tổng quát hóa (Optimization vs. Generalization Gap):** Pareto MTL tối ưu hóa trực tiếp trên *Training Loss*. Trên các mạng nơ-ron sâu dư tham số (over-parameterized như ResNet-18), các hàm mất mát huấn luyện có thể dễ dàng tiến về 0 tại mọi vùng Ω_k, tạo ra một tập nghiệm phân bố rất đều trên không gian Training Loss nhưng lại bị hiện tượng quá khớp (overfitting), làm suy giảm tính đa dạng và độ chính xác trên tập kiểm thử (*Test Accuracy*).

4. **Hội tụ Cục bộ (Local Pareto Optimality):** Do hàm mất mát của mạng nơ-ron sâu không lồi (non-convex), điều kiện KKT chỉ đảm bảo tìm được điểm *Restricted Pareto Critical* cục bộ. Nếu các vector u_k đặt quá sát nhau khiến miền Ω_k quá hẹp, quỹ đạo tối ưu rất dễ bị mắc kẹt tại các điểm tối ưu cục bộ chất lượng thấp trên biên ràng buộc.

8 Tài liệu Tham khảo

[1] Xi Lin, Hui-Ling Zhen, Zhenhua Li, Qingfu Zhang, Sam Kwong. "Pareto Multi-Task Learning." *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, pp. 12060–12070, 2019.

[2] Ozan Sener, Vladlen Koltun. "Multi-Task Learning as Multi-Objective Optimization." *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 525–536, 2018.

[3] Jörg Fliege, Benar Fux Svaiter. "Steepest descent methods for multicriteria optimization." *Mathematical Methods of Operations Research*, 51(3):479–494, 2000.

[4] Bennet Gebken, Sebastian Peitz, Michael Dellnitz. "A descent method for equality and inequality constrained multiobjective optimization problems." *Numerical and Evolutionary Optimization*, Springer, pp. 29–61, 2017.