BÁO CÁO KẾ HOẠCH VÀ LỘ TRÌNH NGHIÊN CỨU LÝ THUYẾT

Đề tài: Xấp xỉ Mặt tiền Pareto Kiểm soát được cho Hệ khuyến nghị Đa bên qua Mạng Siêu tham số (PE-PHN)

Trần Nguyễn Minh Quân
Khoa Công nghệ Thông tin — Trường Đại học Công nghiệp TP.HCM

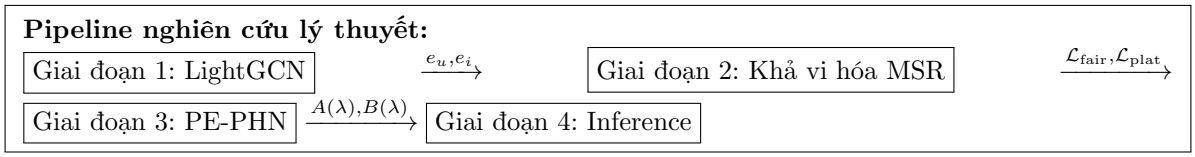
Tháng 10, Năm 2026

Tóm tắt nội dung

Tài liệu này hình thức hóa lộ trình nghiên cứu lý thuyết phục vụ đề tài nghiên cứu khoa học về Hệ thống khuyến nghị đa bên liên quan (Multi-Stakeholder Recommender Systems - MSR). Lộ trình được thiết kế theo mô hình 4 giai đoạn logic kế tiếp: (1) Nền tảng biểu diễn đồ thị với LightGCN; (2) Toán học hóa và khả vi hóa các mục tiêu đa bên; (3) Lý thuyết xấp xỉ mặt tiền Pareto liên tục bằng Hypernetwork kết hợp điều biến hạng thấp (PE-PHN); và (4) Tổng hợp kiến trúc suy diễn kiểm soát thời gian thực. Mỗi giai đoạn đều xác định tường minh đầu vào, nội dung toán học trọng tâm, đầu ra chuyển giao và tiêu chuẩn nghiệm thu.

1 Tổng quan Lộ trình Nghiên cứu (Workflow Overview)

Để tránh phân mảnh kiến thức và tối ưu hóa thời gian nghiên cứu, tiến trình tiếp cận lý thuyết tuân theo nguyên lý kế thừa chặt chẽ: *Đầu ra toán học của giai đoạn trước đóng vai trò là tiên đề hoặc biến số đầu vào trực tiếp cho giai đoạn sau.*



Hình 1: Sơ đồ tuần tự các pha nghiên cứu lý thuyết.

—

2 Giai đoạn 1: Biểu diễn Đồ thị Cơ sở với LightGCN (Base Representation)

2.1 Mục tiêu và Đặt vấn đề

Nghiên cứu cơ chế trích xuất vector biểu diễn (embeddings) tĩnh từ đồ thị tương tác hai phía (Bipartite Graph) $\mathcal{G} = (\mathcal{U}, \mathcal{I}, \mathcal{E})$ giữa người dùng $\mathcal{U}$ và mục $\mathcal{I}$.

2.2 Toán học Cốt lõi

1. **Cơ chế truyền tin không tham số (Neighborhood Aggregation):** Khác với GCN truyền thống, LightGCN loại bỏ phép biến đổi ma trận trọng số W và hàm kích hoạt phi

tuyến tính ReLU, tối ưu hóa quá trình tính toán:

$$e_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u||\mathcal{N}_i|}} e_i^{(k)}, \quad e_i^{(k+1)} = \sum_{u \in \mathcal{N}_i} \frac{1}{\sqrt{|\mathcal{N}_i||\mathcal{N}_u|}} e_u^{(k)} \tag{1}$$

trong đó $\mathcal{N}_u, \mathcal{N}_i$ lần lượt là tập láng giềng bậc 1 của người dùng u và mục i.

2. **Tổng hợp biểu diễn cuối (Layer Combination):**

$$e_u = \sum_{k=0}^{K} \alpha_k e_u^{(k)}, \quad e_i = \sum_{k=0}^{K} \alpha_k e_i^{(k)} \quad (\alpha_k = \frac{1}{K+1}) \tag{2}$$

3. **Hàm mất mát cá nhân hóa BPR (Bayesian Personalized Ranking):**

$$\mathcal{L}_{\text{BPR}} = -\sum_{(u,i,j) \in \mathcal{D}} \ln \sigma\left(\hat{y}_{ui} - \hat{y}_{uj}\right) + \lambda_{\text{reg}} \|\Theta\|_2^2 \tag{3}$$

với $\hat{y}_{ui} = e_u^\top e_i$, $i \in \mathcal{N}_u$ (tương tác dương), $j \notin \mathcal{N}_u$ (tương tác âm).

2.3 Tiêu chuẩn Nghiệm thu Giai đoạn 1

- Chứng minh được bằng giải tích: Tại sao loại bỏ hàm phi tuyến lại giúp mô hình hội tụ tốt hơn trên đồ thị tương tác thưa?
- Triển khai thành công mã nguồn PyTorch tối giản cho LightGCN, trích xuất được ma trận biểu diễn $E_U \in \mathbb{R}^{|\mathcal{U}| \times d}$ và $E_I \in \mathbb{R}^{|\mathcal{I}| \times d}$ ($d = 64$).

—

3 Giai đoạn 2: Khả vi hóa Mục tiêu Đa bên (Differentiable MSR Objectives)

3.1 Mục tiêu và Đặt vấn đề

Các chỉ số đo lường tính công bằng của nhà cung cấp (*Gini*) và độ bao phủ danh mục (*Coverage*) bản chất dựa trên toán tử xếp hạng/đếm (ranking/sorting) rời rạc có gradient bằng 0 ($\nabla = 0$). Giai đoạn này giải quyết bài toán biến đổi các hàm mục tiêu trên thành dạng giải tích khả vi liên tục.

3.2 Toán học Cốt lõi

1. **Kỳ vọng phơi bày khả vi (Differentiable Exposure):** Xấp xỉ xác suất mục i được người dùng u quan sát thông qua hàm phân phối Softmax với tham số nhiệt độ $\tau > 0$:

$$P(i \mid u) = \frac{\exp\left(\hat{y}_{ui}/\tau\right)}{\sum_{j \in \mathcal{I}_{\text{cand}}} \exp\left(\hat{y}_{uj}/\tau\right)} \tag{4}$$

Kỳ vọng tổng phơi bày của mục i trên toàn bộ tập người dùng:

$$E_i = \sum_{u \in \mathcal{U}} P(i \mid u) \tag{5}$$

2. **Hàm mất mát Công bằng Nhà cung cấp (Differentiable Gini Loss):** Gọi $\mathcal{P}$ là tập hợp các nhà cung cấp, và $E_p = \sum_{i \in \mathcal{I}_p} E_i$ là tổng lượng phơi bày của nhà cung cấp p. Hàm mất mát bất bình đẳng Gini khả vi được định nghĩa:

$$\mathcal{L}_{\text{fair}} = \frac{1}{2|\mathcal{P}|^2 \bar{E}_p} \sum_{p \in \mathcal{P}} \sum_{q \in \mathcal{P}} |E_p - E_q| \tag{6}$$

với $\bar{E}_p = \frac{1}{|\mathcal{P}|}\sum_{p\in\mathcal{P}} E_p$. Trong thực nghiệm, hàm giá trị tuyệt đối $|x|$ được làm trơn bằng hàm Huber hoặc $\sqrt{x^2+\epsilon}$.

3. **Hàm mất mát Lợi ích Nền tảng (Negative Catalog Entropy):** Tối đa hóa độ phủ danh mục tương đương với việc tối đa hóa entropy của phân phối phơi bày chuẩn hóa $\bar{P}_i = E_i / \sum_j E_j$:

$$\mathcal{L}_{\text{plat}} = \sum_{i\in\mathcal{I}} \bar{P}_i \ln \bar{P}_i \tag{7}$$

3.3 Tiêu chuẩn Nghiệm thu Giai đoạn 2

- Viết tường minh chuỗi đạo hàm lan truyền ngược (Chain Rule) từ $\mathcal{L}_{\text{fair}}$ và $\mathcal{L}_{\text{plat}}$ qua $P(i \mid u)$ đến vector e_u, e_i.
- Đánh giá tác động của tham số nhiệt độ τ: Khi $\tau \to 0$ (tiến tới hàm chỉ thị Top-1 rời rạc) và khi $\tau \to \infty$ (tiến tới phân phối đều).

—

4 Giai đoạn 3: Pareto Hypernetworks kết hợp LoRA (PE-PHN)

4.1 Mục tiêu và Đặt vấn đề

Thay vì tối ưu hóa nghiệm đơn lẻ qua tổ hợp lồi cố định, giai đoạn này thiết lập cơ chế học toàn bộ bề mặt Pareto $\mathcal{P}^*$ trong một lần huấn luyện duy nhất (1× training run), đồng thời khống chế số lượng tham số để tránh bùng nổ tài nguyên bộ nhớ.

4.2 Toán học Cốt lõi

1. **Không gian vector ưu tiên λ:** Vector λ được lấy mẫu ngẫu nhiên từ phân phối Dirichlet trên đơn hình 3 chiều:

$$\lambda = [\lambda_{\text{user}}, \lambda_{\text{fair}}, \lambda_{\text{plat}}]^\top \sim \text{Dirichlet}(\boldsymbol{\alpha}), \quad \lambda \in \Delta^3 := \left\{ \lambda \in \mathbb{R}^3_{\geq 0} \;\middle|\; \sum_{k=1}^{3} \lambda_k = 1 \right\} \tag{8}$$

2. **Cơ chế sinh tham số thích ứng hạng thấp (Low-Rank Parameter Generation):** Mạng siêu tham số $H_\phi : \Delta^3 \to \mathbb{R}^{4\times(d\times r)}$ nhận λ và sinh trực tiếp 4 ma trận mỏng:

$$[A_u(\lambda), B_u(\lambda), A_i(\lambda), B_i(\lambda)] = H_\phi(\lambda) \quad (A, B \in \mathbb{R}^{d\times r},\ r \ll d) \tag{9}$$

3. **Điều biến biểu diễn động và Tối ưu độ phức tạp suy diễn:** Vector biểu diễn thích ứng tại thời điểm suy diễn được tính từ phải qua trái để duy trì độ phức tạp $\mathcal{O}(d \cdot r)$:

$$e_u(\lambda) = e_u + A_u(\lambda)\left(B_u(\lambda)^\top e_u\right), \quad e_i(\lambda) = e_i + A_i(\lambda)\left(B_i(\lambda)^\top e_i\right) \tag{10}$$

   Điểm số dự đoán tương ứng: $\hat{y}_{ui}(\lambda) = e_u(\lambda)^\top e_i(\lambda)$.

4. **Hàm mất mát tổng hợp và Căn chỉnh góc Cosine (R_{align}):** Để ngăn ngừa hiện tượng suy thoái bề mặt Pareto (Frontier Degeneracy), góc giữa vector tổn thất $\mathbf{L}(\lambda) = [\mathcal{L}_{\text{user}}(\lambda), \mathcal{L}_{\text{fair}}(\lambda), \mathcal{L}_{\text{plat}}(\lambda)]^\top$ và vector ưu tiên λ được tối thiểu hóa:

$$\mathcal{L}_{\text{total}}(\phi) = \lambda^\top \mathbf{L}(\lambda) + \gamma\left(1 - \frac{\lambda^\top \mathbf{L}(\lambda)}{\|\lambda\|_2 \|\mathbf{L}(\lambda)\|_2}\right) \tag{11}$$

4.3 Tiêu chuẩn Nghiệm thu Giai đoạn 3

- Làm rõ bản chất hình học của R_{align}: Chứng minh được $R_{\text{align}} = 0$ khi và chỉ khi vector hàm mất mát thực tế tỷ lệ thuận tuyệt đối với vector mong muốn λ.
- Phân tích chi phí tính toán: So sánh số lượng tham số giữa Hypernetwork đầy đủ sinh bảng embedding $\mathcal{O}((|\mathcal{U}| + |\mathcal{I}|) \times d)$ so với PE-PHN $\mathcal{O}(d \cdot r)$.

—

5 Bảng Kế hoạch Tiến độ và Sản phẩm Chuyển giao

Tuần	Chủ đề nghiên cứu	Nhiệm vụ lý thuyết trọng tâm	Sản phẩm nghiệm thu
1	Khung biểu diễn LightGCN	Khảo sát Message Passing trên đồ thị; phân tích hàm BPR Loss.	Notebook PyTorch LightGCN + Log embeddings.
2	Khả vi hóa MSR	Xây dựng công thức Softmax exposure; chứng minh tính khả vi của Gini & Entropy.	Bản giải tích đạo hàm viết tay + Unit test loss.
3	Pareto Hypernetwork	Khảo sát Dirichlet Sampling; mô hình hóa toán học hàm phạt R_{align}.	Tài liệu phản biện hiện tượng suy thoái bề mặt.
4	Tích hợp PE-PHN & LoRA	Thiết kế kiến trúc $H_\phi(\lambda)$; tối ưu hóa thứ tự nhân ma trận $\mathcal{O}(d \cdot r)$.	Mã giả (Pseudo-code) toàn bộ Training Loop.

Bảng 1: Kế hoạch nghiên cứu lý thuyết 4 tuần.

—

6 Tài liệu Tham khảo Chọn lọc

[1] He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). *LightGCN: Simplifying and powering graph convolution network for recommendation.* ACM SIGIR 2020.

[2] Abdollahpouri, H., Adomavicius, G., Burke, R., et al. (2020). *Multistakeholder recommendation: Survey and research directions.* ACM Computing Surveys (CSUR).

[3] Mehrotra, R., McInerney, J., Bouchard, H., Lalmas, M., & Diaz, F. (2018). *Towards a fair marketplace: Counterfactual evaluation of the trade-off between relevance, fairness & satisfaction in recommendation systems.* ACM RecSys 2018.

[4] Navon, A., Shamsian, A., Chechik, G., & Fetaya, E. (2021). *Learning the Pareto Front with Hypernetworks.* ICLR 2021.

[5] Hu, E. J., Shen, Y., Wallis, P., et al. (2022). *LoRA: Low-Rank Adaptation of Large Language Models.* ICLR 2022.